

# 含 DG 接入的低感知度配电网 数据驱动型电压无功优化

(申请清华大学工学硕士学位论文)

培 养 单 位： 电机工程与应用电子技术系

学        科： 电气工程

研 究 生： 张 宇 精

指 导 教 师： 乔     颖  副研究员

二〇一九年四月

含DG接入的低感知度配电网数据驱动型电压无功优化

张宇精

# **Data-driven voltage and reactive power optimization for low-perspective distribution network with DGs**

Thesis Submitted to  
**Tsinghua University**

in partial fulfillment of the requirement

for the degree of  
**Master Of Science**

in  
**Electrical Engineering**

by  
**Zhang Yujing**

Dissertation Supervisor : Associate Professor Qiao Ying

**April, 2019**



## 关于学位论文使用授权的说明

本人完全了解清华大学有关保留、使用学位论文的规定，即：

清华大学拥有在著作权法规定范围内学位论文的使用权，其中包括：（1）已获学位的研究生必须按学校规定提交学位论文，学校可以采用影印、缩印或其他复制手段保存研究生上交的学位论文；（2）为教学和科研目的，学校可以将公开的学位论文作为资料在图书馆、资料室等场所供校内师生阅读，或在校园网上供校内师生浏览部分内容；（3）根据《中华人民共和国学位条例暂行实施办法》，向国家图书馆报送可以公开的学位论文。

本人保证遵守上述规定。

（保密的论文在解密后遵守此规定）

作者签名： \_\_\_\_\_ 导师签名： \_\_\_\_\_

日 期： \_\_\_\_\_ 日 期： \_\_\_\_\_



## 摘 要

高比例分布式电源接入给配电网电压控制与无功优化带来了新的挑战。目前我国配电网整体处于监控覆盖率低,建模精度不足的低感知度状态,传统基于潮流模型的电压控制方法难以有效应用。针对这一问题,本文采用数据驱动的方法以系统历史运行数据为基础提出了适用于低感知度配电网的电压控制与无功优化方法,论文主要工作及成果如下:

提出了一个适用于调压函数拟合的深度卷积神经网络结构,基于部分观测的历史运行数据直接拟合节点注入有功/无功功率与节点电压之间的调压函数。考虑潮流矩阵与调压函数的数据结构与任务特点设计了深度调压网络,提高了模型的拟合精度和拟合效率。优化后的深度调压网络可以代替由潮流方程确定的无功/有功和电压的映射关系,无需依赖电气参数计算,解决了配电网的低感知度问题。

基于深度调压网络,提出了一种在线梯度回传的电压控制方法。该方法以关键节点电压与参考值的偏差为优化目标,通过控制关键节点电压在参考值附近来实现系统的电压控制。用预训练好的深度调压网络代替传统潮流计算的无功电压灵敏度,提出了在线梯度下降的模型求解方法。控制梯度可以直接通过梯度回传得到,无需依赖系统的潮流模型,可以有效应用于含 DG 的低感知度配电网。仿真结果显示,本文提出的电压控制方法可以使得节点电压分布在参考值附近,有效降低过电压风险,并减小系统网损。

提出了一种基于深度强化学习的连续时间断面下的连续无功优化模型。该模型将传统配电网的无功优化问题转化为一个马尔科夫决策过程,以小化系统网损和动作成本之和为优化目标,以离散无功调节设备的投切指令为控制变量,并采用基于行动者-评论家(Actor-Critic)的深度强化学习算法进行求解。针对潮流矩阵的数据特点分别设计了用来拟合投切策略的行动者网络和用来拟合动作价值函数的评论家网络。所提方法用深度神经网络直接拟合系统状态到离散无功调节设备的投切动作的函数关系,在与实际配电网的交互过程中完成网络训练。相比传统无功优化方法,该模型无需进行分段,且不依赖于日前的负荷与分布式电源出力预测,可以实现实时的多时间断面下的连续无功优化,提高了系统运行经济性。

**关键词:** 低感知度配电网; 电压控制; 无功优化; 数据驱动; 分布式电源

## Abstract

Voltage management and reactive power optimization in distribution networks is challenged by increasing penetration of distributed generations. China's distribution systems are generally in low-perceptance state according to low telemetry rate and modeling accuracy. The traditional voltage control method based on power flow model is no longer suitable for low-perceptance distribution systems. Aiming at this problem, a model-free voltage control and reactive power optimization method for low-perspective distribution network based on the historical operation data is proposed. The main contributions and work of the thesis are shown as follows:

A deep convolutional neural network which is suitable for voltage management function fitting is proposed. A deep neural network is used to directly fit the relationship between the nodal injection power flow and the node voltage, which we called voltage management function, on the historical operation data. Based on the data characteristics, a deep voltage-management network is designed to improve the fitting accuracy and efficiency of the model. The well-trained deep voltage-management network can replace the voltage management function determined by the power flow equation, and does not need to rely on the calculation of electrical parameters to solve the low-perceptibility problem of the distribution network.

A voltage control method based on deep voltage-management network is proposed. The method takes the deviation of the pilot node voltage from the reference value as the optimization target, and realizes the voltage control of the system by controlling the voltage of the pilot node not deviate the reference value. A pre-trained deep voltage-managemnet network is used to replace the reactive voltage sensitivity, and gradient descent is used to solve the optimization model. The control gradient can be calculated by backpopagation, without relying on the power flow equation. So it can be effectively applied to the low-perceptance distribution networks. The simulation results show that the voltage control method proposed in this thesis can make the nodal voltage distribution near the reference value, effectively reduce the overvoltage risk and reduce the system network loss.



A continuous reactive power optimization model based on deep reinforcement learning under multi-time section is proposed. This model transforms the reactive power optimization problem of the traditional distribution network into a Markov decision process. A deep neural network is used to directly fit the functional relationship of the system state to the switching action of the discrete device, and the structure of the deep neural network is optimized for the data characteristics of the power flow matrix. In the process of interaction with the actual distribution network, the reinforcement learning algorithm is used to train the network. Compared with the traditional reactive power optimization method, the proposed model does't divided a day to several sections and does not depend on the load and distributed generation prediction. It can realize continuous reactive power optimization under real-time and improve the system operation economy.

**Key words:** low-perceptance distribution systems; voltage management; reactive power optimization; data-driven; distributed generation

# 目 录

第 1 章 引言 .....	1
1.1 研究背景和意义 .....	1
1.2 研究问题及技术思路 .....	2
1.3 国内外研究现状 .....	3
1.3.1 传统配电网电压控制方法 .....	3
1.3.2 DG 参与配电网电压控制研究现状 .....	4
1.3.3 配电网无功优化研究现状 .....	6
1.3.4 深度卷积神经网络 .....	7
1.3.5 深度强化学习 .....	8
1.4 本文主要工作 .....	10
第 2 章 数据驱动电压控制与无功优化的数学基础 .....	12
2.1 低感知度配电网 .....	12
2.2 模型驱动与数据驱动方法比较 .....	14
2.3 数据驱动的配电网电压控制与无功优化框架 .....	14
2.4 电压控制与无功优化数学模型 .....	15
2.4.1 集中式电压控制数学模型 .....	15
2.4.2 无功优化数学模型 .....	16
2.5 深度卷积神经网络与深度强化学习 .....	17
2.5.1 深度卷积神经网络 .....	17
2.5.2 深度强化学习 .....	21
第 3 章 基于卷积神经网络的低感知度配电网调压函数拟合 .....	26
3.1 本章概述 .....	26
3.2 基于卷积神经网络的调压函数拟合 .....	26
3.2.1 调压函数拟合任务的数据特点 .....	26
3.2.2 深度调压网络 .....	27
3.3 调压函数拟合的合理性解释 .....	29
3.3.1 潮流方程约束下节点电压与注入功率之间的关系 .....	29
3.3.2 考虑出力相关性的调压函数拟合 .....	30
3.3.3 深度调压网络对数据量的需求 .....	32

3.4 算例分析 .....	33
3.4.1 算例系统介绍 .....	33
3.4.2 深度调压网络训练细节与训练结果 .....	34
3.4.3 网络结构对拟合结果的影响 .....	35
3.4.4 训练数据量对拟合结果的影响 .....	37
3.4.5 系统感知度敏感性分析 .....	38
3.5 本章小结 .....	40
<b>第4章 基于深度调压网络的含高比例 DG 的配电网电压控制</b> .....	<b>41</b>
4.1 本章概述 .....	41
4.2 基于潮流模型的电压控制方法的局限性 .....	41
4.3 适用于低感知度配电网的集中式电压控制模型 .....	42
4.4 基于深度调压网络的电压控制方法 .....	43
4.4.1 基于梯度下降的集中式电压控制 .....	43
4.4.2 电压控制流程 .....	44
4.4.3 关键节点的参考值设置 .....	47
4.5 算例分析 .....	48
4.5.1 潮流倒送引起的电压越限现象 .....	48
4.5.2 不同电压控制方法下的电压曲线 .....	50
4.5.3 不同电压控制方法下的节点电压分布 .....	52
4.5.4 不同电压控制方法下的网损对比 .....	54
4.6 本章小结 .....	55
<b>第5章 基于深度强化学习的配电网连续无功优化</b> .....	<b>57</b>
5.1 本章概述 .....	57
5.2 配电网无功优化的强化学习建模方法 .....	57
5.2.1 无功优化的数学模型 .....	57
5.2.2 配电网无功优化的马尔科夫决策过程 .....	58
5.3 基于深度强化学习的配电网动态无功优化 .....	62
5.3.1 深度神经网络结构 .....	62
5.3.2 神经网络优化算法 .....	63
5.4 算例分析 .....	64
5.4.1 算例系统介绍 .....	64
5.4.2 深度强化学习训练过程 .....	65

5.4.3 仿真结果 .....	66
5.5 本章小结 .....	72
第 6 章 结论 .....	74
参考文献 .....	76
致 谢 .....	81
声 明 .....	82
个人简历、在学期间发表的学术论文 .....	83

## 第1章 引言

### 1.1 研究背景和意义

近年来,我国分布式电源(DG)发展迅速,多省份形成了“点多面广,局部高密度并网”的发展态势。截至2018年底,我国以分布式光伏为主的分布式电源装机容量达到5061万千瓦<sup>[1]</sup>,相较前一年增长71%,远高于同期集中式光伏电站与风力发电装机容量增长率(分别为23%和11%),分布式电源已经成为我国可再生能源发展的新的增长点<sup>[2]</sup>。

目前我国分布式电源的接入电压等级主要有35kV、10kV和380/220V,占比分别为19.89%、40.57%和39.54%。高渗透率的分布式电源很大程度上改变了中低压配电网电网形态与潮流分布,给配电网的电压控制带来了新的挑战<sup>[3-4]</sup>。

其一,双向潮流引起电压分布改变。分布式电源的大量接入使得配电网从传统的“无源网”变为“有源网”,潮流分布不再是从变压器低压侧到负荷端单向流动,节点电压沿馈线逐渐降低的结论也不再成立<sup>[5]</sup>。甚至在光伏出力较高时还会发生由“潮流倒送”引起的电压越限事件。传统配电网通过控制馈线首末端电压(即首端节点不越上限,末端节点不越下限)来保障沿线节点电压合格的方法不再适用。

其二,配电网电压波动性增强。分布式电源的接入使得配电网节点电压变化范围增大,电网末端节点在分布式电源大发负荷较小时有过电压风险,在分布式电源出力不足负荷较大时又面临欠电压风险<sup>[6]</sup>。与此同时,分布式电源波动远比负荷波动更加剧烈,在十几分钟内就可能发生从满发到零出力的变化且预测精度较低,在十几分钟内就可能发生从满发到零出力的变化。加之预测精度较低,传统基于负荷预测曲线分段优化电容/抗器投切方法难以满足电压控制要求。

其三,配电网整体处于“低感知度状态”,难以照搬大电网的自动电压控制方法。一方面,我国配电网通信系统的建设仍处于初级阶段。据统计,接入电压等级在35kV及以下的DG只有49%将二遥(遥测、遥信)信息接入到了调度系统中,四遥接入率更是不足10%。另一方面,配电网的线路参数杂散性强,网络结构不易完全掌握,在我国的调度系统中35kV以下电压等级的配电网几乎没有精确的潮流参数模型<sup>[7]</sup>。上述限制使低压配电网的潮流状态估计难以建模、收敛困难,整体处于“低感知度状态”,无法支撑自动电压控制与无功优化等高级应用。

虽然分布式电源的随机性与波动性给配电网的电压控制和无功优化带来了很

多困难，但分布式电源逆变器同时也是一种可连续调节的优质无功源，其无功出力可简单地通过改变逆变器控制算法实现，几乎没有调节成本和次数限制，且无容量约束时与有功出力相互解耦。分布式电源的接入也大大丰富了配电网的无功调节手段，可与配电网传统的离散无功调节设备（并联电容器、有载调压变压器等）相配合共同实现电压控制和无功优化。

在充分考虑配电网的低感知度情况下，合理地利用系统中的连续调节设备与离散调节设备进行电压控制与无功优化可以有效提高系统的稳定性与经济性，对配电网的安全高效运行有重要意义。

## 1.2 研究问题及技术思路

根据配电网当前所面临的现状与问题，本文致力于在建模精度与通信系统约束条件下，合理利用多类型无功调节资源，实现对低感知配电网的电压控制与无功优化，以提高配电网运行的安全性与经济性。本文研究的关键难点主要在于配电网的低感知度状态使得系统的潮流方程模型很难获得，而传统的电压控制与无功优化方法均以潮流模型为基础，无法适用于低感知配电网。对于以上技术问题与研究难点，本文求解的技术思路如下：

（1）针对配电网的低感知度问题，本文采用数据驱动的方法进行求解。节点注入功率与节点电压之间的函数关系是电压控制的关键，然而在低感知度配电网中，该函数关系难以直接由潮流方程以模型驱动的方式获得。近些年，以深度神经网络为基础的数据驱动方法在大数据技术的推动下解决了很多传统模型难以解决的问题<sup>[8]</sup>。本文借鉴其思想，用一个深度神经网络直接拟合节点注入功率与节点电压之间的非线性函数关系，并针对潮流矩阵与调压函数的数据结构与任务特点，设计相应的适用于调压函数拟合的神经网络结构，提高模型的拟合效率。基于系统历史运行数据对深度神经网络进行训练，用训练好的深度神经网络代替用潮流方程表示的隐函数关系，作为无潮流模型电压控制与无功优化的基础。

（2）针对潮流分布改变引起的配电网沿线电压分布差异大的问题，本文选择用配电网中的 DG 等连续调节设备进行电压控制，来提高配电网的电压水平。电压控制的主要目的是防止系统越限电压，进而使得节点电压满足优化的电压曲线。配电网中以分布式电源逆变器为代表的连续无功调节设备动作周期短（通常为分钟级），没有调节次数的约束，可以频繁动作，且几乎没有调节成本，可以实现实时的电压控制。为适应配电网的低感知度状态，本文用深度神经网络拟合得到的调压函数代替无功电压灵敏度，并通过梯度回传，采用梯度下降法求解优化模型。调压函数与控制梯度均是在系统历史运行数据上，采用数据驱动的方法得到

的，无需潮流模型，因此可以实现无模型的电压控制。

(3) 针对分布式电源导致的配电网系统状态波动大、电容/电抗需反复动作问题，本文利用配电网中的离散无功调节设备进行连续无功优化，以减小系统网损、减少离散设备动作次数，提高系统运行经济性。无功优化的目标是考虑分布式电源与负荷波动，在多时间断面下优化系统经济性。配电网中以并联电容器为代表的离散调节设备动作间隔不宜太短，且有一定的调节次数上限，折算至调节过程中动作成本不可忽略，更适用于长时间尺度的无功优化。本文将配电网动态无功优化问题转化为一个多阶段决策问题，以最小化系统网损和设备动作成本之和作为优化目标，以离散动作设备的投切指令作为控制变量。本文用深度神经网络直接拟合系统状态到设备投切指令之间的函数关系，在与电网的交互过程中采用强化学习算法进行训练，无需潮流模型，因此可以实现无模型的无功优化。

### 1.3 国内外研究现状

#### 1.3.1 传统配电网电压控制方法

无分布式电源接入的传统配电网中常用的无功补偿设备主要包括并联电容器、SVG、DSTATCOM等<sup>[9]</sup>，其中并联电容器造价低廉且可以有效为配电网提供电压支撑，是传统配电网中主要的无功补偿装置。

与高压输电网不同，配电网通常呈馈线结构。在无分布式电源接入的传统配电网中，潮流单向流动，从变压器低压侧流向负荷，电压沿潮流方向下降，配电网首端节点电压最高，末端节点电压最低。因此，传统配电网中可利用变电站中的有载调压变压器和线路中的并联电容器控制电网首端节点不越上限，末端节点不越下限即可保证整体电压合格。

##### 一、变电站电压无功控制策略

变电站无功电压控制的主要目标是保证电网节点电压不越限，并平衡区域内的无功需求，减少无功流动，实现区域内补偿，从而降低网损。变电站无功电压控制策略最为经典的控制方式是基于“九区图”实现的<sup>[10]</sup>。九区图法以电压和无功作为控制标准，通过固定的电压和无功上下限将整个区域分为井字形的九个区域，每个区域分别对应相应的动作，通过最简单的大小比较的方式实现无功电压控制，实现简单，是目前系统中实际应用最为广泛的策略

然而基本的九区图法是基于固定的无功与电压上下界决定设备的动作方式的，难以适应系统不同的运行状态，且在某些情况下还会导致设备的反复动作，减少设备寿命。针对这一问题，有的研究通过在九区图法中增加防振区进行缓解<sup>[11]</sup>。

也有其他一些研究改进九区图法提出如五区图、十一区图、十七区图等的多区图控制<sup>[12]</sup>方法，相比简单的九区图法可以得到更好的效果，但基本思想一致，均是电压-无功空间进行划分，根据系统所处区域决定设备动作。

## 二、并联电容器投切策略

并联电容器是配电网最为重要的无功补偿装置，可以有效为配电网提供电压支撑，防止电网末端节点电压越下限，改善系统电压水平。并联电容器的投切策略主要有按照时间投切、按照电压投切、按照无功投切和按照功率因数投切几种方式<sup>[13]</sup>。

按照时间投切需要负荷的预测曲线，提前设定好投切时间和组数，由于目前无功整体的预测精度较差，难以预测得到精确的无功曲线，因此应用较少。按照电压投切以某些节点的电压量测值作为输入，以投切动作作为输出，需要提前设定好投切策略，可以有效方式电压越限，是目前常用的控制手段。按照无功和功率因数的投切与按电压投切策略类似，只不过输入改变成了无功或功率因数测量值，通过限制无功或功率因数可以更好的减少系统中无功的流动，实现就地补偿，从而减少网损。

传统配电网的电压分布规律简单，控制设备也较少，有载调压变压器和并联电容器均只能离散动作，动作空间很小，优化空间不大，因此可以用较为简单的控制策略实现系统的电压控制。然而高比例分布式电源接入后，会影响到配电网的潮流分布，传统配电网中潮流单向流动的结论不再成立，电网末端节点也可能会发生电压越上限的事故，仅通过控制首末端节点已经无法保证系统整体电压合格。同时分布式电源作为一种可连续调节的无功源也丰富了配电网的无功调节手段，需要引入针对分布式电源接入后配电网新的特点设计相应的电压调节策略，以满足配电网电压控制的需求。

### 1.3.2 DG参与配电网电压控制研究现状

分布式电源的无功出力可简单地通过改变逆变器控制算法实现，几乎没有调节成本和次数限制，可以连续进行调节，且既可以发出容性无功又可以发出感性无功，是一种非常优质的无功源。分布式电源参与配电网的电压控制是近几年研究的热点问题，按照通信方式的不同分布式电源接入的配电网电压控制主要包括三种模式——就地式电压控制、分散式电压控制和集中式电压控制<sup>[14-15]</sup>。

就地式电压控制仅需利用本地的量测信息，无需外界通信系统协助，对通信系统要求最低，是目前最为常用的控制手段<sup>[16-17]</sup>。配电网的就地式电压控制主要包括 $Q-V$ 下垂控制<sup>[18]</sup>、 $\cos\varphi-P$ 下垂控制<sup>[19]</sup>和 $Q-P$ 下垂控制<sup>[20]</sup>等，这里后者为



控制输入物理量，前者为控制输出的物理量。不难发现，配电网就地式电压控制主要为各种下垂控制算法，由于仅能利用本地的量测信息，难以实现系统整体的无功协调，可能会出现网损增加<sup>[21]</sup>、功率因数恶化<sup>[22]</sup>等问题，甚至有可能因为参数设置不当导致系统发生电压振荡<sup>[23]</sup>。

分散式电压控制策略中分布式电源并网点仅与临近节点之间进行通信，通过对系统精确建模后，采用分布式优化算法进行电压控制<sup>[24-26]</sup>。文献<sup>[27-28]</sup>通过模型推导得到了优化目标对节点注入功率的梯度，然后采用梯度下降法进行电压控制，文献<sup>[29]</sup>进一步证明了当配电网节点电压之间相角相差不大时，保证所有节点电压一致可以最小化网损，从而可以利用分布式算法达到全局最优，文献<sup>[14]</sup>中详细总结了目前研究中常用的分布式电压控制方法，在此不再详述。

集中式电压控制方式对通信系统的要求最高，需要分布式电源接入调控主站。配电网的集中式电压控制方法主要参考高压输电网中二级电压控制的数学模型，将电压控制问题转化为带约束的优化问题，常用的优化目标包括节点电压偏差<sup>[30]</sup>，无功出力<sup>[31]</sup>，系统网损<sup>[32]</sup>，有功出力成本<sup>[29]</sup>等，约束条件包括节点电压约束，无功上下限约束以及潮流方程约束。潮流方程约束的存在使得集中式电压控制问题为非凸优化，很多研究将潮流方程线性化，用无功电压灵敏度近似表示节点注入功率与节点电压之间的函数关系，从而将集中式电压控制转化为凸优化问题，可以直接进行求解。

还有一些研究将不同的控制方法进行组合<sup>[33-34]</sup>，文献<sup>[35-36]</sup>提出了一种将集中控制与就地控制方法相结合的控制方法，下层的就地控制采用  $Q-V$  下垂控制策略来快速响应系统电压变化，上层的集中式控制策略通过调整就地控制的控制参数来进一步防止电压越线，并平衡各节点无功出力。文献<sup>[37-38]</sup>采用了多模式的控制方法，系统在不同的运行状态下采用不同的控制模式，以满足系统在不同条件下的控制需求。文献<sup>[39]</sup>研究了不同电压控制方式对新能源接入率的影响，研究表明有效的电压控制手段可以大大提高配电网的新能源接入能力，同时对比发现集中式的电压控制方法可以更有效的提高新能源接入率并减小网损。

总结来说，集中式电压控制可以有效的实现全局优化，统一调配可控制资源，同时减少因节点间的耦合作用而导致的电压震荡问题，可以达到最佳的控制效果。但是集中式电压控制对通信系统要求最高，需要分布式电源接入调控主站，低感知度配电网难以满足这一条件。同时，低感知度配电网的网络结构不清，无精确的电气参数，传统集中式电压控制模型中的潮流方程约束或由潮流方程线性化后得到的无功电压灵敏度矩阵难以直接得到。针对低感知度配电网的这些客观条件，需要重新设计适用于低感知度配电网的电压控制模型。

### 1.3.3 配电网无功优化研究现状

由于配电网中的负荷与分布式电源出力在不断变化,因此系统中的无功调节设备需要不断动作以调节系统中的无功分布,来保证系统运行的经济性。通常将考虑负荷及分布式电源出力变化,并满足离散无功调节设备动作次数约束的优化问题定义为动态无功优化或连续无功优化<sup>[40-41]</sup>。

传统的连续无功优化问题常以系统网损作为优化目标,以并联电容器、有载调压变压器等离散调节设备的动作序列作为控制变量,约束条件主要考虑系统的节点电压约束,调节设备的档位约束,系统潮流方程约束,以及设备动作次数约束。设备动作次数约束使得动态无功优化成了一个复杂的多时空耦合优化问题,时间维度上需要决定设备在哪些时候动作,空间维度上又要决定哪些设备进行动作。从数学定义上来说,配电网的动态无功优化属于高维非线性混合整数规划,很难直接进行求解,目前的研究主要分为以下几种求解思路——负荷分段法<sup>[42-43]</sup>、模型简化法<sup>[44]</sup>、成本函数法<sup>[45-46]</sup>以及智能算法<sup>[41]</sup>。

负荷分段法通常是按照设备动作次数约束将一天划分为固定时段,并假设只有各时段之间离散无功调节设备可以发生动作,因此可以天然满足设备的动作次数约束,从而实现时间上的解耦<sup>[47]</sup>。并且在时间段内部,负荷分段法假设负荷不发生变化,并用预测均值进行代替,从而将动态优化问题转化为了静态问题。负荷分段法的求解精度与分段数目相关,分段数目越多,每个时间段的长度就越短,对系统状态的拟合越精确,同时问题规模越大,求解越复杂。负荷分段法可以将动态优化转化为静态优化问题,求解相对简单,是目前应用最为广泛的方法。然而,分布式电源的出力波动性远高于负荷,在短时间内便可发生出力的大范围波动,分段法很难能够精确描述其出力特性。

模型简化法的思路是将动作空间进行简化从而降低模型的求解难度。文献[48-49]采用多阶段的求解方法,将动态优化问题转化成了非线性规划和混合整数规划的两阶段优化问题,实现了对模型的简化。文献[50]通过对投切序列进行聚类从而模型的简化。文献[51]将模型中的潮流方程转化为二阶锥约束,从而将非凸优化问题转化为了近似的凸优化问题。然而模型简化法通常需要对动作空间或状态空间做出一定假设,与系统实际运行过程有一定差异。并且随着问题规模的增大,模型复杂度也会随之增加,造成求解困难。

成本函数法的主要思想是在优化目标中加入动作成本项来代替动作次数约束,将动作次数的硬约束转化为动作成本的软约束,从而实现时间上的解耦<sup>[52]</sup>。然而针对实际系统,离散动作设备的动作成本通常难以准确建模,给这一方法的应用带来困难。

由于配电网的动态无功优化属于非线性混合整数规划问题，传统优化方法难以直接求解，因此很多研究采用如遗传算法<sup>[47]</sup>、粒子群算法<sup>[53]</sup>、模拟退火算法<sup>[54]</sup>等智能算法对模型进行求解。也有一些研究将智能优化算法与负荷分段法或模型简化法相结合，先对模型进行化简，然后采用智能算法进行求解<sup>[47]</sup>。然而，智能算法计算效率较低，收敛时间长，且无法保证所得结果的最优性。

总结来说，分段法实现在时间上解耦且求解简单是目前最常用的无功优化方法。但是对于含高比例 DG 的低感知度配电网，DG 的波动性比传统负荷更强，在十几分钟内就可能发生从满发到零出力的变化，难以分段化简。同时，传统的无功优化方法受到日前的负荷与分布式电源出力预测精度的影响，分布式电源的日前预测精度目前仍难以满足要求。此外，传统无功优化算法中作为约束条件的潮流方程，在低感知度配电网也难以直接获得。因此，针对负荷与分布式电源出力的强波动性，研究适用于低感知度配电网的实时决策的连续无功优化模型具有重要意义。

#### 1.3.4 深度卷积神经网络

近些年，数据驱动的深度学习方法开启了新的人工智能研究热潮，并且在计算机视觉<sup>[55]</sup>、自然语言处理<sup>[56-57]</sup>与语音识别<sup>[57-59]</sup>等领域取得了远超传统方法的丰硕成果。目前常用的深度神经网络结构主要有广泛应用于计算机视觉领域的深度卷积神经网络（Convolutional Neural Network, CNN）、应用于自然语言处理领域的循环神经网络<sup>[60]</sup>（Recurrent Neural Network, RNN）和用于无监督学习的深度置信网络<sup>[61-62]</sup>（Deep Belief Network, DBN）。由于本文主要应用深度卷积神经网络，因此仅以 CNN 为例简单介绍深度学习的研究进展。

上世纪 90 年代，Yann LeCun 以图像中的卷积算子为基础提出了原始的卷积神经网络结构，并在一些简单的计算机视觉任务中取得了很好的效果<sup>[63]</sup>。2012 年，Hinton 实验室提出了具有 8 个卷积层的深度卷积神经网络结构——Alex Net<sup>[64]</sup>，并一举取得了 ImageNet 图像分类大赛的冠军，其 Top 5 的分类准确率达到 16.4%，远超传统方法，由此开启了深度学习的大门。Alex Net 将多个卷积层相互堆叠的网络结构实现特征复用，提高模型效率，并将传统神经网络中的 sigmoid 激活函数换成了 relu 函数，基本解决了梯度消失问题，使得模型可以端到端的进行训练。

2014 年，19 层的深度卷积神经网络——VGG 夺得了当年 ImageNet 的冠军，Top 5 的分类准确率达到 7.3%<sup>[65]</sup>。VGG 与 Alex Net 的网络结构相差不大，都是采用卷积层加全连接层的网络结构，只是 VGG 用预训练的方式实现了更深的网络结构，并选择了更小的卷积核。

2015 年, 何恺明提出了 152 层的深度残差网络<sup>[66]</sup> (ResNet), ResNet 借鉴了传统计算机视觉中的残差表示法, 在卷积层上加入了直连通道。ResNet 卷积层的卷积层不再简单拟合特征映射, 而是拟合特征映射的残差, 进一步提高了模型拟合效率。同时直连通道的引入也使得梯度可以直接回传到每一层特征映射, 进一步解决了梯度消失的问题, 甚至已经使得其突破了网络深度的限制, 1000 余层的 ResNet 也可有效训练。ResNet 不仅是 2015 年 ImageNet 的冠军, 而且其 Top 5 的分类准确率达到了 3.57%, 超越了人类的识别精度。

2017 年, Dense Net 吸收了 ResNet 的思想, 在每一层之间均加入了直连通道, 使得模型精度得到进一步的提升<sup>[67]</sup>。

CNN 网络结构的快速发展, 推动了很多计算机视觉其他领域的突破。基于深度卷积神经网络的方法在物体检测, 语义分割, 视频跟踪, 图像风格化等<sup>[68-69]</sup>很多任务上均实现了对传统方法的突破。

由于电力系统的潮流矩阵也像图像一样属于典型的矩阵结构数据, 近些年也有将 CNN 应用于电力系统的很多尝试, 在故障检测<sup>[70]</sup>, 负荷预测<sup>[71]</sup>, 暂态稳定评估<sup>[72]</sup>等领域也已经得到了广泛应用, 并取得了一定的突破。根据“没有免费的午餐定理”, 没有哪一个机器学习模型可以适用于所有任务, 需要针对不同的任务设计不同的模型。目前将深度卷积神经网络应用于电压控制的研究还处于起步阶段, 相关文献较少, 且较少研究讨论了配电网潮流矩阵的数据结构与电压控制任务的特点。针对潮流矩阵的数据结构与任务特点设计相应的神经网络结构可以有效提高模型的拟合精度与拟合效率, 对模型的实际应用有重要意义。

### 1.3.5 深度强化学习

与监督学习、无监督学习等不同, 强化学习解决的是另一类的动态决策问题。强化学习最早的研究是为了解决控制问题, 上世纪 60 年代, 贝尔曼在研究最优控制理论过程中, 提出了著名的贝尔曼最优方程<sup>[73]</sup>, 奠定了强化学习的理论基础。1988 年, Sutton 首先提出了时间差分算法<sup>[74]</sup>, 可以更高效的利用与环境的交互数据, 采用自举的方式无模型地实现强化学习问题的求解。1989 年, 另一种以值函数为基础的无模型 Q 学习算法也很快面世<sup>[75]</sup>。20 世纪初, Sutton 又提出了策略梯度法, 可以直接对策略进行学习<sup>[76]</sup>。至此, 强化学习的理论框架基本搭建完毕。

强化学习的理论发展很快在不同领域中得到应用, 然而传统的强化学习算法受限于维度灾难问题, 很难应用于状态空间与动作空间很大的问题。随着深度学习的快速发展将深度学习与强化学习相结合的深度强化学习方法开始出现, 2013 年 Deep Mind 公司提出了 DQN 模型<sup>[77]</sup>, 用深度卷积神经网络解决状态空间爆炸的

问题，并在电子游戏上达到甚至超过了人类水平。2015年，Deep Mind 公司又提出了基于深度强化学习的围棋算法 AlphaGo<sup>[78]</sup>，打败了世界围棋冠军李世石，使得深度强化学习开始走进大众的视野。

深度强化学习方法主要可以分为三种——基于值函数的方法、基于策略的方法和行动者-评论家方法。

基于值函数的方法以当前观测到的环境状态作为模型输入，以动作价值函数作为模型输出。其代表就是 DQN<sup>[77]</sup>，DQN 直接以游戏画面的原始像素作为模型的输入，然后用深度卷积神经网络抽取其中的关键特征，并拟合得到动作空间的动作价值函数，得到最优控制策略。此后，针对 DQN 存在的过优化等问题，又有 DDQN<sup>[79]</sup>、Dueling DQN<sup>[80]</sup>等算法相继问世，在大多数的游戏上，基本都达到甚至超过了人类水平。

基于策略的方法是将传统的策略梯度法与深度神经网络相结合，直接用深度神经网络拟合策略，以当前观测到的环境状态作为模型输入，以动作或动作的概率分布作为模型输出。基于策略的方法直接以动作作为输出，无需进行离散化出力，因此可以有效解决动作空间的维度爆炸问题，实现连续动作的控制。

行动者-评论家方法（Actor Critic，AC）是将基于值函数的方法与基于策略的方法相结合，因此具备两种方法的优点，是目前研究的热点方向。优势函数行动者评论家算法（A2C）用动作优势函数代替 AC 算法中的累积回报，大大提高了模型的收敛性。为了提高数据的利用效率，PPO 算法采用重要性采样的思想，提出了异策略的 A2C 算法<sup>[81]</sup>。为了解决数据的相关性问题，Deep Mind 采用多个仿真环境并行的方式提出了异步优势行动者评论家算法（A3C）<sup>[82]</sup>，在大多数任务上达到了目前最好的效果。除此之外，针对确定性的动作策略，也有一些算法根据 AC 框架被相继提出，如 DPG<sup>[83]</sup>和 DDPG 算法<sup>[84]</sup>等。

传统的强化学习方法在无功优化问题中已有相关研究<sup>[85-86]</sup>。对于实际配电网，节点注入功率与节点电压为连续变量，需要对其进行离散化处理，离散化分段越细越接近于系统实际情况，但同时状态空间越大，动作空间也会随着设备的增多呈指数方式上升，因此传统强化学习算法难以有效解决状态空间与动作空间的维度灾难问题，在实际的大规模系统中难以有效应用。同时目前已有研究主要还是模型驱动的强化学习算法如动态规划等，需要对系统详细建模得到状态转移概率，难以适用于低感知度配电网<sup>[87]</sup>。采用深度强化学习算法，可以直接将配电网的注入功率与节点电压的量测值作为状态空间，用深度神经网络提取关键特征用于动作决策，可以有效解决维度灾难问题，并无需系统的潮流模型，可以有效应用于低感知度配电网。

## 1.4 本文主要工作




图 1.1 本文整体研究思路

本文聚焦低感知配电网的电压控制与无功优化问题，以深度神经网络为基础，在系统历史运行数据上用数据驱动的方式解决了配电网的低感知度问题，提出了无模型的配电网连续无功调节设备的电压控制与离散调节设备的无功优化方法，整体研究思路如图 1.1 所示。本文主要工作可以分为以下三个部分：

(1) 基于深度卷积神经网络的配电网调压函数拟合。考虑到中低压配电网的低建模精度与低四遥覆盖率，用一个深度卷积神经网络直接拟合得到节点注入功率与节点电压之间的调压函数关系。针对潮流矩阵与调压函数的数据结构与任务特点，设计一个适用于调压函数拟合的神经网络结构——深度调压网络。用系统历史运行数据与深度卷积神经网络解决配电网的低感知度问题，作为后文电压控制与无功优化的基础。

(2) 基于深度调压网络的含高比例 DG 的配电网电压控制。提出一种适用于低感知度配电网的集中式电压控制模型，该模型以关键节点电压与参考值的偏差为优化目标，以系统中的连续调节设备如分布式电源逆变器的无功出力为控制变量，通过控制关键节点电压在参考值附近来实现系统的电压控制，增大系统的电压裕度并提高系统稳定性。模型中用深度调压网络拟合得到的函数关系代替无功电压灵敏度，用梯度下降法对模型进行求解。控制梯度可以直接通过梯度回传得

到，无需系统的潮流模型，从而实现无模型的集中式电压控制。

(3) 基于深度强化学习的配电网连续无功优化。将传统配电网的无功优化问题转化为一个马尔科夫决策过程，以最大化累积奖励为控制目标，实现系统的无功优化。用深度神经网络直接拟合系统状态到离散无功调节设备的投切动作的函数映射，并用深度强化学习算法对模型进行训练。模型训练是在调度系统与配电网的交互过程中完成的，无需依赖于精确的潮流模型，可以有效应用于低感知度配电网。




图 1.2 论文文章节结构

论文的章节结构安排如图 1.2 所示，除了第 1 章引言和第 6 章结论外，其他章节安排如下。第 2 章首先详细介绍了传统电压控制与无功优化的数学模型和深度卷积神经网络与深度强化学习的基本概念，作为后文的数学基础。第 3 章用一个深度卷积神经网络对节点注入功率与节点电压之间的调压函数关系进行拟合，并将这个深度卷积神经网络命名为深度调压网络。第 4 章研究的是配电网中连续调节设备的电压控制方法，以深度调压网络为基础，提出了无模型依赖的配电网电压控制模型。第 5 章研究配电网中离散调节设备的无功优化方法，将传统无功优化模型转化为一个动态决策问题，并用深度强化学习进行求解。

## 第2章 数据驱动电压控制与无功优化的数学基础

为了可以有效应用于低感知度配电网，本文以系统的历史运行数据为基础将数据驱动的方法应用于配电网的电压控制和无功优化问题中，提出无模型的求解方法。本文用一个深度卷积神经网络直接拟合节点注入功率和节点电压之间的函数关系，从而解决配电网的低感知度问题。然后针对配电网中的连续无功调节设备，用深度神经网络代替传统电压控制模型中的灵敏度矩阵，用梯度下降法进行模型求解，实现无模型的电压控制。最后针对配电网中的离散无功调节设备，将传统配电网无功优化模型转化为一个多阶段决策问题，用一个深度神经网络直接拟合设备投切策略，用深度强化学习算法进行求解，实现无模型的无功优化。

本章将根据以上研究内容与研究方法，简单介绍配电网中的电压控制与无功优化的数学模型以及深度卷积神经网络和深度强化学习的基本知识，作为后文的研究基础。本章第1节首先根据中低压配电网实际的运行状况，给出低感知度配电网原型，明确低感知配电网的建模条件。第2节简单介绍数据驱动与模型驱动的建模思想差异。第3节提出数据驱动的低感知度配电网电压控制与无功优化的整体框架。第4节介绍传统配电网中的电压控制与无功优化的数学模型。第5节首先介绍目前深度卷积神经网络的相关概念与基本的网络结构，然后介绍强化学习算法的基础知识与常用的深度强化学习方法。

### 2.1 低感知度配电网

目前我国分布式电源接入电压等级主要有 35kV、10kV 和 380/220V，占比分别为 19.89%、40.57% 和 39.54%。相比高压输电网，分布式电源接入的中低压配电网主要有如下特点：

(1) 整体建模精度低。中低压配电网的线路参数杂散性强，节点电压和注入功率之间的非线性关系更为突出，加上扩建速度快、网络结构更新经常滞后。因此很难用传统的潮流模型对中低压配电网进行精细化建模，在我国的调度系统中 35kV 以下电压等级的配电网几乎没有精确的潮流参数模型，状态估计难以收敛，因此基于潮流模型的无功电压灵敏度方法难以直接应用。

(2) 通信系统建设落后。由于建设成本限制，我国配电网通信系统相较于输电网仍处于较为初级的阶段。据 2018 年中统计，接入电压等级在 35kV 及以下的 DG 只有 49% 将相关信息接入到了调度系统中，四遥接入率更是不足 10%。



总结来说，分布式电源接入下的中低压配电网整体处于网架结构不清，参数精度不高，信息接入率较低的“低感知状态”，配电网的电压控制与无功优化必须考虑到这些限制条件。

一个典型的 DG 接入的低感知度配电网原型如图 2.1 所示。其中支路可以分为在调度系统中已知网络结构与参数的已知支路（在图中用实线表示）和在调度系统中未知网络结构与参数的未知支路（在图中用虚线表示）。系统中除 DG 外，还有传统的离散无功调节设备如并联电容器等，在图中用 SC 表示。




图 2.1 DG 接入的低感知度配电网原型

系统节点包括四遥接入调度主站的可观测节点和未接入调度主站的不可观测节点（只接入二遥、三遥的节点也归于此类节点）。可观测节点和不可观测节点均可分为分布式电源接入节点和负荷接入节点，并假设所有并联电容器均接入可观测节点，如式(2-1)所示

$$\mathcal{N} = \mathcal{N}^0 \cup \mathcal{N}^X = (\mathcal{N}_{DG}^0 \cup \mathcal{N}_L^0 \cup \mathcal{N}_{SC}^0) \cup (\mathcal{N}_{DG}^X \cup \mathcal{N}_L^X) \quad (2-1)$$

其中  $\mathcal{N}$  表示所有节点集合， $\mathcal{N}^0$  表示所有可观测节点集合， $\mathcal{N}^X$  表示所有不可观测节点集合， $\mathcal{N}_{DG}^0$  和  $\mathcal{N}_{DG}^X$  分别表示可观测和不可观测分布式电源接入的节点集合， $\mathcal{N}_L^0$  和  $\mathcal{N}_L^X$  分别表示可观测和不可观测负荷接入的节点集合， $\mathcal{N}_{SC}^X$  表示并联电容器接入的节点集合。为方便后文表述定义节点注入功率集合如下：

$$(\mathbf{P}, \mathbf{Q}) = \bigcup_{N_i \in \mathcal{N}} \{P_i, Q_i\} \quad (2-2)$$

$$(\mathbf{P}^0, \mathbf{Q}^0) = \bigcup_{N_i \in \mathcal{N}^0} \{P_i, Q_i\} \quad (2-3)$$

$$(\mathbf{P}_{DG}^0, \mathbf{Q}_{DG}^0) = \bigcup_{N_i \in \mathcal{N}_{DG}^0} \{P_i, Q_i\} \quad (2-4)$$

其中  $(\mathbf{P}, \mathbf{Q})$  表示所有节点的注入功率集合， $(\mathbf{P}^0, \mathbf{Q}^0)$  表示可观测节点的注入功

率集合,  $(\mathbf{P}_{DG}^0, \mathbf{Q}_{DG}^0)$  表示可观测分布式电源并网点注入功率集合。

## 2.2 模型驱动与数据驱动方法比较

在配电网的电压控制与无功优化问题中, 为了符合系统实际运行情况, 节点注入功率和节点电压之间需要满足潮流方程的约束。模型驱动的方法通常假设潮流方程已知, 并直接将潮流方程作为优化模型的约束条件。本质上, 这种方法已经默认对电力系统做了一定的抽象, 即用潮流方程来表示电力系统稳态的运行过程, 并假设潮流方程中需要的系统参数和潮流方程所需观测量已知, 即系统是完全可知的。数据驱动的方法则不假设潮流方程已知, 仅将电力系统抽象为需要满足特定规律的实际系统, 在系统的历史运行数据中挖掘实际的运行规律, 并将从数据中挖掘到的规律应用于系统的电压控制与无功优化中。

相比之下, 模型驱动的方法对系统的描述可解释性更强, 也更为可靠, 然而需要对系统网络结构, 网络参数与运行状态有足够认知, 难以有效应用于低感知度配电网。数据驱动的方法无需精确的潮流模型, 对系统感知度要求较低, 但需要大量有效的系统历史运行数据, 运算需求通常也更高, 需要更大的算力。近些年, 大数据与云计算的快速发展使得无模型的数据驱动方法逐渐成为可能。

## 2.3 数据驱动的配电网电压控制与无功优化框架

分布式电源接入下的配电网中同时包含分布式电源逆变器等连续无功调节设备和并联电容器等离散无功调节设备。连续调节设备动作周期短, 通常为分钟级, 没有调节次数的约束, 可以频繁动作, 且几乎没有调节成本。而离散调节设备动作周期长, 通常为小时级, 每天有一定的调节次数上限, 且调节过程中动作成本不可忽略。如何协调这两种设备之间的关系是配电网电压控制的关键。本文的求解思路是利用离散调节设备进行长时间尺度的无功优化, 利用连续调节设备进行实时的电压控制。

针对配电网的低感知状态, 本文提出数据驱动的适用于低感知配电网的电压控制与无功优化框架, 如图 2.2 所示。电压控制和无功优化的核心分别是两个神经网络——深度调压网络和投切决策网络。控制过程主要分为两步——利用系统历史的运行数据离线训练和利用实时数据在线控制, 分别在图中用绿色线和红色线表示, 和神经网络训练相关的部分在图中用虚线表示。从时间尺度上, 可分为分钟级的实时电压控制和小时级的系统无功优化, 控制对象分别是系统中的连续调节设备 (DG) 和离散调节设备 (SC), 如图 2.2 中所示。




图 2.2 数据驱动的配电网电压控制与无功优化框架

## 2.4 电压控制与无功优化数学模型

### 2.4.1 集中式电压控制数学模型

配电网电压控制的主要目标是防止节点电压越限，并使得系统节点电压满足特定的电压曲线。现有的配电网的集中式电压控制方法主要借鉴的是高压输电网中的二级电压控制模型。高压输电网中的电压控制采用“分区”控制方法。根据节点之间的相互影响，将系统分为若干控制区域，并假设区域之间并不相互影响，每个区域单独进行电压控制。然后再从每个区域中选择某些有代表性的节点作为“先导节点”，这些先导节点的电压可以在一定程度上代表系统整体电压水平，因此仅控制先导节点电压在参考值附近，并保证节点电压不越限即可。这种分区控制方法可以有效的降低模型求解复杂度，从而可有效应用于实际系统中。传统二级电压控制数学模型如下式所示：

$$\begin{aligned}
 & \min \|U_p - U_p^{ref} + C_p \Delta Q_g\|^2 \\
 & s.t. \quad U_k^{\min} \leq U_k + C_k \Delta Q_g \leq U_k^{\max} \\
 & \quad Q_g^{\min} \leq Q_g + \Delta Q_g \leq Q_g^{\max}
 \end{aligned} \tag{2-5}$$

其中， $U_p$  是先导节点电压实际值， $U_p^{ref}$  是先导节点电压参考值， $U_k$  是关键节点电压实际值（需控制关键节点电压不越限）， $U_k^{\min}$  和  $U_k^{\max}$  分别是关键节点电压上下限， $Q_g$  是控制发电机的无功出力， $\Delta Q_g$  是控制发电机的无功调整量， $Q_g^{\min}$  和

$Q_g^{\max}$  是分别是控制发电机的无功出力上下限,  $C_p$  和  $C_k$  分别是控制发电机节点对先导节点和关键节点的无功电压灵敏度。无功电压灵敏度按照式(2-6)定义:

$$C \equiv \frac{\Delta U}{\Delta Q} \quad (2-6)$$

如式(2-5)所示的二级电压控制模型, 以先导节点电压与参考电压的偏差作为优化目标, 以控制发电机无功调整量为控制变量, 考虑了关键节点电压的上下限约束和控制发电机无功容量约束。控制发电机无功出力与节点电压之间的关系用无功电压灵敏度矩阵简化, 使得该模型为一个凸优化问题, 可以方便的进行求解。无功电压灵敏度矩阵相当于直接将潮流方程进行线性化处理, 直接将潮流方程进行泰勒展开, 并忽略高阶项, 仅保其中的留线性项可得无功电压灵敏度矩阵  $C$  即为节点电压对无功潮流的雅可比矩阵。

#### 2.4.2 无功优化数学模型

动态无功优化的目的主要是在满足无功调节设备的实际运行条件约束下, 通过调整系统的无功分布减少系统网损, 提高系统运行的经济性。传统的动态无功优化问题的优化目标可以下式表示:

$$\min \sum_{i=1}^{24} f_i(X, T) \quad (2-7)$$

其中  $X$  表示系统的状态变量,  $T$  表示离散控制变量,  $f_i$  表示评价函数, 通常为系统网损。传统模型将全天分为 24 个时段, 最终的优化目标即为求解每个时段评价函数之和的最小值。模型的约束条件可以表示为

$$\begin{cases} U^{\min} \leq U \leq U^{\max} \\ Q^{\min} \leq Q \leq Q^{\max} \\ T^{\min} \leq T \leq T^{\max} \\ g_i(X, T) = 0 \quad t = 1, 2, \dots, 24 \\ s_{ci} \leq s_c^{\max} \quad i = 1, 2, \dots, m \\ s_{tj} \leq s_t^{\max} \quad j = 1, 2, \dots, l \end{cases} \quad (2-8)$$

其中  $U$ ,  $U^{\min}$  和  $U^{\max}$  分别为节点电压和电压上下限,  $Q$ ,  $Q^{\min}$  和  $Q^{\max}$  分别为节点注入功率和功率上下限,  $T$ ,  $T^{\min}$  和  $T^{\max}$  分别表示控制变量和控制变量上下限,  $g_i(X, T) = 0$  表示时段  $i$  内的潮流方程约束,  $s_{ci}$  和  $s_c^{\max}$  分别是电容器的投切次数和投切上限,  $m$  为电容器个数,  $s_{tj}$  和  $s_t^{\max}$  分别为变压器分接头的调节次数和调节次数上限,  $l$  为有载调压变压器个数。

配电网的无功优化模型以最小化系统运行成本为优化目标，以并联电容器、有载调压变压器等离散调节设备的动作序列作为控制变量，约束条件主要考虑系统的节点电压约束，调节设备的档位约束，系统潮流方程约束，以及设备动作次数约束。动作设备动作次数约束与系统潮流方程约束使得配电网的动态无功优化是一个“大规模、多时空、强耦合”的非线性混合整数规划问题，很难用传统算法直接求解。

## 2.5 深度卷积神经网络与深度强化学习

### 2.5.1 深度卷积神经网络

#### 2.5.1.1 卷积运算

卷积运算表示的是两个函数之间的运算关系，是卷积神经网络的基本运算。一个常见卷积运算可以表示为下列形式

$$S = I * K \quad (2-9)$$

其中卷积运算用符号 $*$ 表示， $I$ 为卷积运算的输入（Input）， $K$ 为卷积运算的卷积核或者核函数（Kernal）， $S$ 为卷积运算的输出（Output）有时也称其为特征（Feature Map）。卷积神经网络主要用于二维矩阵或者多维矩阵结构数据，对于二维卷积运算，计算公式如下

$$S(i, j) = (I * K)(i, j) = \sum_m \sum_n I(m, n) K(i - m, j - n) \quad (2-10)$$

一个简单的二维卷积运算示意图如图 2.3 所示。




图 2.3 卷积运算示意图

在此例中，输入为一个二维  $3 \times 4$  矩阵，卷积核大小为  $2 \times 2$ ，输出为  $2 \times 3$  维矩阵。对于三维卷积运算，输入和卷积核均增加一个通道（Channel）维，每个通道内分别如图 2.3 所示进行卷积运算之后进行求和得到输出，因此每一个卷积核对应一个二维的输出。如果卷积核个数超过 1，则可以得到一个三维的输出，输出的 channel 数与卷积核数目相当。

### 2.5.1.2 深度卷积神经网络基本结构

上世纪 90 年代，Yann LeCun 以图像中的卷积算子为基础提出了原始的卷积神经网络结构，并在一些简单的计算机视觉任务中取得了很好的效果。但是真正使得卷积神经网络开启深度学习研究热潮的是 2012 年 Hinton 实验室提出 Alex Net 一举取得了 ImageNet 图像分类赛的冠军，并且分类精度远超传统方法。之后针对不同的任务特点，很快又有更多的卷积神经网络被相继提出，但是整体框架与设计思想均大同小异，与最早的 Alex Net 差别不大。因此选择以 Alex Net 为例说明深度卷积神经网络的基本结构。




图 2.4 Alex Net 网络结构示意图

Alex Net 的基本网络结构如图 2.4 所示，一个典型的深度卷积神经网络主要包括卷积层（Convolutional Layer）、池化层（Pooling Layer）、全连接层（Fully Connected Layer）以及激活函数等。在 2015 年又有学者提出了批正则化层（Batch Normalization Layer, BN 层）可以加速模型收敛，提高预测精度，因此 BN 层后来也成为了深度卷积神经网络的基本组成结构。接下来分别简单介绍这几个基本结构。

**卷积层（Convolutional Layer）**，卷积层是深度卷积神经网络最主要的组成结构，一个卷积层有若干个卷积核组成。每个卷积核均对应一个对输入的卷积运算，对于最为常用的二维卷积，输入通常为一个维度为  $(N, C_{in}, W_{in}, H_{in})$  的矩阵，其中  $N$  是批大小，是卷积神经网络的可调参数， $C_{in}$  是输入的通道数， $W_{in}$  是输入的宽， $H_{in}$  是输入的高。输出维度为  $(N, C_{out}, W_{out}, H_{out})$ ，含义与输入基本一致。其中  $C_{out}$  是输

出的通道数，由卷积核的个数决定， $W_{out}$  和  $H_{out}$  由下式决定

$$W_{out} = \left\lfloor \frac{W_{in} + 2 \times P[1] - KS[1]}{ST[1]} + 1 \right\rfloor \quad (2-11)$$

$$H_{out} = \left\lfloor \frac{H_{in} + 2 \times P[0] - KS[0]}{ST[0]} + 1 \right\rfloor \quad (2-12)$$

其中  $P$ 、 $KS$ 、 $ST$  均为可设置的二元整数参数，其后所跟 0 或 1 表示为第一个参数或第二个参数。 $P$  表示给输入边缘填充 0 的数目， $KS$  表示卷积核的大小， $ST$  表示卷积运算的步长。

卷积层可以有效从输入中提取关键特征作为特征映射，然后将输出的特征映射再作为下一卷积层的输入，从而实现特征的组合，且使得下一卷积层可以从中提取更高阶的特征。卷积层的层层堆叠实现“深度”卷积神经网络。

**池化层（Pooling Layer）**同样是卷积神经网络中的重要概念。本质上池化层是一种降采样方法，根据采样标准的不同可以分为最大池化层（Max Pooling）和平均池化层（Average Pooling）等。池化层的主要作用是减小网络参数，降低模型复杂度。

**全连接层（Fully Connected Layer）**即为传统的多层感知机结构，全连接层内神经元之间是稠密连接的，即下一层的神经元与上一层的每一个神经元全部相连，全连接层的主要作用是学习得到从特征映射到模型输出的分类器或者拟合器，因此在全连接层的最后要根据任务类型设置相应的激活函数，比如对于二分类问题，激活函数应取为 sigmoid 函数，对于多分类问题，激活函数应取为 softmax 函数。

**批正则化层（BN Layer）**使得每  $N$ （批大小）个数据作为一批（batch），然后按批对模型进行训练，bn 层的计算公式如下式所示

$$y = \frac{x - E[x]}{\sqrt{Var[x] + \varepsilon}} * \gamma + \beta \quad (2-13)$$

其中， $x$  为 bn 层的输入， $y$  为 bn 层的输出， $E[x]$  和  $Var[x]$  分别为  $x$  的均值和方差， $\beta$  和  $\gamma$  分别表示训练集所有数据的均值和方差， $\varepsilon$  是很小的正数，以保证分母不为 0。经过 bn 层后，每层的输出在每一批数据上均值和方差相同，相当于在训练的过程中对每层神经网络的输出进行归一化处理，保证数据的“同分布”假设，解决了内部分布偏移问题（Internal Covariate Shift），可以使得模型收敛更加稳定，并在一定程度上加快训练速度。

**激活函数（activation function）**是对作用在神经元输出上的非线性函数的总称，激活函数可以给神经网络提供非线性，提高神经网络的拟合能力。传统神经网络

的激活函数主要使用 sigmoid 函数，sigmoid 函数的饱和特性使得神经网络会出现梯度消失的现象，导致多层的神经网络难以端对端的训练。Alex Net 首先使用 Relu 函数作为激活函数，其表示式如下

$$y = \begin{cases} x & x \geq 0 \\ 0 & x < 0 \end{cases} \quad (2-14)$$

Relu 函数计算简单，且可以有效解决梯度消失的问题，保证模型可以端对端的进行训练，因此是目前最为常用的激活函数。

### 2.5.1.3 卷积神经网络的建模思想

深度卷积神经网络的结构设计主要包含了以下的一些建模思想。

一、特征复用。相比较简单的通过增加前馈神经网络隐含层神经元的数目来增加模型参数。深度卷积神经网络通过多个卷积层的堆叠使得模型更“深”来提高模型的表达能力。深度卷积神经网络中前层卷积输出的特征映射作为后层的输入，因此后层卷积相当于对于前层特征的重新组合，提高了特征的利用效率。在计算机视觉任务中，浅层卷积通常提取得到的是颜色、纹理等局部特征，而最后几层深层卷积则可以提取得到轮廓、边缘等全局特征。特征的复用可以有效提高参数的利用效率。

二、局部连接。传统神经网络的每一个神经元均与前层的输出完全连接，前层神经元的输出与一个稠密的系数矩阵相乘后作为下一层的输入。而深度卷积神经网络的神经元仅与上一层部分神经元的输出相连，数目与卷积核大小一致，即系数矩阵是稀疏的。和每层神经元相连的输入的范围大小称为该层感受野，随着层数的逐渐增多，感受野也会逐渐增大。当模型足够深时，深层卷积层的感受野可以完全覆盖输入矩阵。深度神经网络采用局部连接的网络结构主要是由于图像具有局部特性，很多特征仅需通过图片上的部分像素便可准确判断，而无需以图像整体作为模型输入。

三、权值共享。卷积神经网络中稀疏的系数矩阵中，对应于同一个卷积核的系数是相同的，即神经网络的部分权值是共享的。权值共享的思想来自于图像的空间不变性，即对于很多任务来说，同样的特征位于图像的不同位置（如位于左上角还是右下角）对输出的影响不大，因此通过权值共享可以进一步的减少模型参数，降低模型复杂度，提高模型效率。

深度卷积神经网络针对图像等矩阵数据的特点而进行的网络结构设计使得模型效率大大提高。其通过局部连接与权值共享的方式使得其网络参数远小于同等规模的全连接网络，在几乎不降低模型的表达能力的同时大幅降低了模型的复杂



度，因此可以在更小的数据集上进行训练。深度卷积神经网络的成功离不开其背后针对数据与任务特点的网络结构设计思想的指导。

## 2.5.2 深度强化学习

### 2.5.2.1 强化学习基本概念

相比较于监督学习、无监督学习与半监督学习，强化学习解决的是另一类的动态决策问题。强化学习的研究主体是智能体或决策主体（Agent），Agent 可以感知到环境（Environment）的状态（state），并根据一定的策略做出对环境的动作（Action），环境根据动作反馈给 Agent 动作之后的下一状态，以及奖励（reward），然后开始下一阶段的交互过程，并重复进行。决策主体的训练是在与环境的交互过程中完成的，一个简单的决策主体与环境的交互过程示意图如图 2.5 所示。

相比较于监督学习，强化学习的动作没有明确的标签，即在训练的过程中不知道正确的动作是什么，只能在不断的尝试中通过环境返回的奖励对智能体进行训练。而且，与损失函数不同的是环境的反馈经常会存在一定的延时，即当前动作对环境的影响需要经过多步之后才会逐渐显出效应。举例来说在下围棋过程中，我们通常并不会在每下完一步后得到任何奖励，而是只有在游戏结束之后，才能根据输赢得到反馈。




图 2.5 决策主体与环境的交互过程示意图

一个强化学习问题可以用马尔科夫决策过程进行建模（Markov Decision Process, MDP）。一个典型的马尔科夫决策过程可以由  $\langle S, R, P, A, \gamma \rangle$  五个变量定义。其中， $S$  是状态空间，是决策主体所能够感知到环境的所有状态（ $s$ ）的集合。 $A$  是动作空间，是决策主体所能够对环境进行动作（ $a$ ）的集合，如果动作空间为连续变量则称为连续动作，如果动作空间为离散变量则称之为离散动作。 $R$  是回报空间，是环境根据状态和动作返回给决策主体的即时回报（ $r$ ）的集合，是评价状态与动作的指标。 $\gamma$  是回报折扣率，表示对未来回报的折算系数。 $P$  是状态转移

概率，由环境确定，同时在马尔科夫决策过程中，状态转移概率满足马尔科夫性，如下式所示

$$P(s_{t+1} | s_1, a_1, \dots, s_t, a_t) = P(s_{t+1} | s_t, a_t) \quad (2-15)$$

即当前所处的状态与采取的动作仅对下一时刻的状态有影响，而不会影响到之后的状态，即马尔科夫决策过程是无后效性的。

**策略** ( $\pi$ ) 定义为从状态空间到动作空间的一个函数映射  $\pi: S \rightarrow A$ ，如果动作  $a$  是确定的则称之为确定性策略  $a = \pi(s)$ ，如果  $a$  为一个概率分布则称之为随机策略  $\pi(a | s)$ 。在一个马尔科夫决策过程中，**累积折扣回报** ( $G_t$ ) 由下式定义

$$G_t = r_t + \gamma r_{t+1} + \gamma^2 r_{t+2} + \dots \quad (2-16)$$

**状态价值函数** ( $v^\pi(s)$ ) 定义为累积折扣回报的期望值，即

$$v^\pi(s) \equiv E(G_t | s_t = s) \quad (2-17)$$

其中的上标  $\pi$  表示的是在策略  $\pi$  下的状态价值函数，由于策略决定了动作的分布从而影响到状态转移概率与即使奖励，因此在不同策略下同一状态的状态价值不同。

**动作价值函数** ( $q^\pi(s, a)$ ) 定义为在状态  $s$  下，执行动作  $a$  后的累积折扣回报的期望值，即

$$q^\pi(s, a) \equiv E(G_t | s_t = s, a_t = a) \quad (2-18)$$

同样上标  $\pi$  表示的是在策略  $\pi$  下的动作价值函数，根据状态价值函数与动作价值函数，**动作优势函数** ( $A^\pi(s, a)$ ) 可由下式定义

$$A^\pi(s, a) \equiv q^\pi(s, a) - v^\pi(s) \quad (2-19)$$

即动作优势函数为动作价值函数与状态价值函数的差值，表示的是在状态  $s$  下采取动作  $a$  带来的收益。

理论上可以证明，在马尔科夫决策过程中存在一个最优的策略  $\pi^*$  可以使得在该策略下任意状态的状态价值函数均大于其他策略下的的状态价值函数，即

$$v^*(s) = \max_{\pi} v^\pi(s) \quad (2-20)$$

强化学习的目的就是通过学习决策主体与环境的交互过程去学习最优策略  $\pi^*$ 。上世纪 60 年代，贝尔曼在研究最优控制理论过程中，提出了著名的如下式所示的贝尔曼最优方程 (Bellman Equation)

$$v^*(s) = \max_a \left( r(s, a) + \gamma \sum_{s' \in S} P_{ss'}^a v^*(s') \right) \quad (2-21)$$

$$q^*(s, a) = \max_a \left( r(s, a) + \gamma \sum_{s' \in S} P_{ss'}^a \max_{a'} q^*(s', a') \right) \quad (2-22)$$

其中  $s'$  表示状态  $s$  的后继状态,即当前状态的最优状态价值函数与动作价值函数可以用下一状态的最优状态价值函数与动作价值函数表达,从而可以递推求解。贝尔曼最优方程给强化学习提供了理论基础。

### 2.5.2.2 深度强化学习

强化学习算法在上世纪九十年代就已经开展了广泛的研究与应用,然而真正让强化学习算法走进大众视野的,还是深度学习发展之后,将深度神经网络与强化学习相结合的深度强化学习,深度强化学习可以有效的解决传统强化学习中存在的“维度灾难”问题,并在一系列任务上取得了超越人类的表现。深度强化学习方法主要可以分为三种——基于值函数的方法 (Value Based Method)、基于策略的方法 (Policy Based Method) 和行动者-评论家方法 (Actor Critic Method, A2C),接下来分别简单介绍这几种方法

#### 一、基于值函数的方法

基于值函数的方法源自传统强化学习的 Q 学习 (Q Learning) 方法,理论上可以证明最优按照下式动作的策略即为最优策略

$$\pi^*(a|s) = \begin{cases} 1 & \text{if } a = \arg \max_{a \in A} q^*(s, a) \\ 0 & \text{else} \end{cases} \quad (2-23)$$

即在每个状态下均选择动作价值函数最大的动作就是最优策略。因此如果学习得到了最优动作价值函数便得到了最优策略。

深度强化学习中基于值函数的方法便是直接用深度神经网络来拟合最优动作价值函数  $q^*$ , 其中最有名的是 Deep Mind 在 2013 年提出的 DQN 算法。Deep Mind 将 DQN 算法用于经典的 Atari 游戏中,其直接以游戏画面的原始像素作为模型的输入,然后用深度卷积神经网络抽取其中的关键特征,然后以动作空间的  $q$  值作为模型的输出。DQN 算法直接利用贝尔曼方程得到网络拟合的目标,损失函数可以表示如下

$$L = (\hat{y} - Q(s, a | \theta))^2 \quad (2-24)$$

其中  $\theta$  为 DQN 的网络参数,  $\hat{y}$  为近似的优化目标,根据贝尔曼方程可以由下式表示

$$\hat{y} = r(s, a) + \gamma \max_{a'} Q(s', a' | \theta) \quad (2-25)$$

其中  $s'$  为后继状态,  $a'$  为状态  $s'$  下可以采取的动作。除了用深度卷积神经网络端到端的直接拟合动作价值函数来解决维度灾难问题外。DQN 还采用了经验回放机制, 并提出了目标网络来提高训练速度等方法来提高模型的训练效率, 具体内容在此不再详述, 见原始论文。

DQN 之后又相继有人提出了 DDQN、Dueling DQN 等结构对 DQN 进行了改进, 但是基本思想一致, 即用深度卷积神经网络直接拟合动作价值函数, 并利用贝尔曼方程作为优化目标进行网络训练。

## 二、基于策略的方法

基于策略的深度强化学习方法同样采用深度神经网络来解决维度灾难的问题, 但是相比基于值函数的方法, 基于策略的方法直接以动作  $a$  作为模型的输出, 即神经网络是直接对策略进行拟合  $a = \pi_{\theta}(s)$ , 其中  $\theta$  表示深度神经网络的参数。在二十世纪初, 强化学习的奠基性人物 Sutton 提出了策略优化方法 (Policy Gradient, PG) 可以直接对策略进行优化。

对于一个马尔科夫决策过程, 其概率可以表示为

$$p_{\theta}(\tau) = p(s_1)\pi_{\theta}(a_1 | s_1)p(s_2 | s_1, a_1)\pi_{\theta}(a_2 | s_2) \dots \quad (2-26)$$

其中  $\tau$  表示该马尔科夫决策过程。强化学习的优化目标可以等效为最大化累积收益的期望, 即

$$\max E(R(\tau)) = E\left(\sum_i r(s_i, a_i)\right) \quad (2-27)$$

其中期望定义在所有不同的马尔科夫决策过程出现的概率上, 因此优化目标可以改写为

$$\max E(R(\tau)) = \sum_{\tau} R(\tau)p_{\theta}(\tau) \quad (2-28)$$

对于上式, 我们可以直接对参数  $\theta$  求梯度, 然后采用梯度上升法最大化目标函数, 目标函数对参数的梯度可以用下式进行计算

$$\nabla_{\theta} E(R(\tau)) = E_{\tau} \left( \nabla_{\theta} \log(\pi_{\theta}(a | s)) R(\tau) \right) \quad (2-29)$$

根据上式可以定义策略梯度法的损失函数如下

$$J(\theta) = -E(R(\tau)) = E_{\tau} \left( -\log(\pi_{\theta}(a | s)) R(\tau) \right) \quad (2-30)$$

如果用一个深度神经网络来拟合策略  $\pi_{\theta}(a | s)$ , 并在和环境的交互过程中用式 (2-30) 定义的损失函数对神经网络进行更新, 就是基于策略的深度强化学习方法。

### 三、行动者-评论家方法

很多实验表明，将优化目标中的累积奖励换成动作优势函数  $A(s,a)$  可以帮助模型更好的收敛，即将优化目标改写为

$$J(\theta) = E_{\tau} \left( -\log(\pi_{\theta}(a|s)) A(s,a) \right) \quad (2-31)$$

如果我们用一个网络直接拟合策略，用另一个神经网络拟合动作优势函数  $A(s,a)$ ，则得到了行动者-评论家方法（Actor Critic，A2C）。

行动者-评论家方法是将基于值函数的方法与基于策略的方法进行结合得到的。行动者-评论家方法包括两个网络——动作网络（Actor Net，或行动者网络）和评价网络（Critic Net，或评论家网络）。Actor Net 与基于策略的深度强化学习方法类似，直接用神经网络拟合得到状态到动作的映射关系，即拟合策略  $a = \pi_{\theta}(s)$ ，优化目标如式(2-31)所示。Critic Net 与基于值函数的方法类似，用神经网络拟合得到状态价值函数（ $v_{\theta'}(s)$ ），动作价值函数（ $q_{\theta'}(s,a)$ ）或者直接拟合动作优势函数（ $A_{\theta'}(s,a)$ ），然后根据贝尔曼方程，得到近似的拟合目标，进行求解。

通常来说，基于值函数的方法对数据的利用效率更高，而基于策略的方法的收敛稳定性更好，更容易收敛，而 A2C 方法则可以有效的结合二者的优点，是目前研究最为广泛的方法。

除了基本的 A2C 方法外，近些年又相继出现了基于 A2C 的 DDPG 算法、PPO 算法、A3C 算法等，对 A2C 方法进行了一定的改进得到了更好的效果，但是基本思想与 A2C 方法一致，在此不再展开，详细内容见原始论文。

## 第3章 基于卷积神经网络的低感知度配电网调压函数拟合

### 3.1 本章概述

电力系统进行无功电压控制与无功优化最关键的一步是建立节点电压与注入功率之间的函数关系—— $U = \varphi(P, Q)$ ，我们将这一函数关系定义为调压函数。传统模型驱动电压控制与无功优化方法中，调压函数关系常用无功电压灵敏度为系数的线性函数表示。配电网的参数杂散性和非线性更强，仅用无功电压灵敏度难以精确描述配电网的调压函数关系。此外，传统方法的调压函数关系是用潮流方程隐式表示的，也难以有效应用于低感知度配电网。

针对以上问题，本章内容采用数据驱动的方法，根据系统历史运行数据解决系统的低感知度问题。考虑到中低压配电网的低建模精度与低四遥覆盖率，用一个深度卷积神经网络直接拟合得到节点注入功率与节点电压之间的调压函数关系。针对潮流矩阵与调压函数的数据结构与任务特点，设计一个适用于调压函数拟合的深度调压网络结构。深度调压网络以可观测节点注入潮流矩阵作为模型输入，以关键节点电压作为模型输出，仅需系统历史的运行数据进行模型训练，无需潮流模型，可以解决配电网的低感知度问题，作为后文电压控制与无功优化的基础。

本章内容安排如下，第2节首先分析调压函数拟合的数据特点，作为后文深度神经网络结构设计的基础，然后针对分析得到的数据特点，设计了一个适用于调压函数拟合的深度卷积神经网络结构。第3节讨论了在潮流方程约束下，用深度神经网络拟合调压函数的合理性。第4节采用一个加入DG的IEEE 33节点系统作为算例，分析了所提方法的有效性。

### 3.2 基于卷积神经网络的调压函数拟合

#### 3.2.1 调压函数拟合任务的数据特点

传统二级电压控制模型中，通常直接采用潮流模型线性化的方式得到无功电压灵敏度矩阵，从而得到节点注入功率到节点电压之间的调压函数关系。然而针对前文所述低感知度中低压配电网，节点注入功率与节点电压之间的较强的非线性使得基于灵敏度矩阵的线性关系误差较大。并且对于无法获得准确潮流模型的低感知系统，也难以直接从潮流模型中获得灵敏度矩阵。因此，本文选择采用一个

深度神经网络来拟合可观测节点注入功率( $\mathbf{P}^0, \mathbf{Q}^0$ )到节点电压 $U$ 之间的非线性函数关系。

深度神经网络由于其强大的函数拟合能力推动了人工智能的快速发展,在图像处理、语音识别、NLP 等领域均取得了很大成功。我们选择采用深度神经网络根据系统历史运行数据,以数据驱动的方法直接拟合调压函数。根据万能拟合定理,“有激活函数的单隐层神经网络可以在任意精度下拟合任意函数”,即对于 $\forall \varepsilon > 0$

$$\begin{aligned} \exists F(x) &= \sum_{i=1}^N v_i \sigma(w_i^T x + b_i) \\ \text{s.t. } |F(x) - f(x)| &< \varepsilon \end{aligned} \quad (3-1)$$

虽然一个简单的但隐层神经网络已经有足够的表达能力去拟合调压函数,但根据“没有免费的午餐”定理,仍然需要设计一个合适的网络结构以提高拟合精度与计算效率。针对潮流方程约束下的数据形式与特征,经过大量实验发现了适用于调压函数拟合的网络结构的如下特点:

(1) 对于调压函数的拟合,卷积神经网络结构的表现优于简单的全连接网络。节点注入潮流矩阵作为模型的输入属于典型的矩阵结构数据,并且在配电网中如果沿着馈线结构依次安排节点序号,那么系统中相邻节点在潮流矩阵也处于相邻位置。经过简单的节点排序优化,潮流矩阵作为输入也像图像一样具有局部特性。在此数据特点下,卷积神经网络可以更有效地提取潮流数据中的关键特征。

(2) 采用较大的卷积核时电压拟合效果更好。中低压配网中任一节点电压受到几乎所有节点注入功率的影响,较大的卷积核可以提高模型的感受野,使模型能够感知到系统整体的状态从而提高拟合效果。

(3) 传统卷积神经网络中常用的池化层(pooling layer)会降低电压拟合精度。因为电压拟合是一个细粒度的拟合问题,同时潮流矩阵的规模通常远小于图像数据,不太需要加入池化层来降低模型复杂度,因此不建议加入池化层。

### 3.2.2 深度调压网络

针对以上电力系统潮流数据的结构与特点,用一个深度卷积神经网络来拟合可观测节点注入功率与节点电压之间的调压函数关系,并将其命名为深度调压网络,网络结构示意图如图 3.1 所示。深度调压网络以可观测节点注入潮流矩阵作为模型输入(潮流矩阵经过了节点排序优化),以关键节点电压作为模型输出。对于一个有 $n$ 个可观测节点, $m$ 个关键节点的低感知配电网。深度调压网络的输入维度为 $2 \times n$ ,输出维度为 $1 \times m$ ,输入输出数据格式定义如式(3-2)所示。




图 3.1 深度调压网络示意图

$$\begin{aligned}
 \text{输入: } & \left[ P_i^0 \quad Q_i^0 \right]^T \Big|_{2 \times n} \quad N_i \in \mathcal{N}^0 \\
 \text{输出: } & \left[ U_j \right]^T \Big|_{1 \times m} \quad N_j \in \mathcal{N}^k
 \end{aligned} \tag{3-2}$$

其中  $\mathcal{N}^k$  为关键节点，在电压控制过程中需保证其节点电压不越限，并尽量不偏离参考值。深度调压网络的损失函数定义为关键节点电压的预测值与实际量测量值之间的均方误差（Mean Square Error, MSE），如式(3-3)所示：

$$\mathcal{L} = \frac{1}{m} \times \|U - \hat{U}\|_2 = \frac{1}{m} \times \sum_{i=1}^m (U_i - \hat{U}_i)^2 \tag{3-3}$$

其中  $\hat{U}$  为关键节点电压的实际量测值，维度为  $1 \times m$ ，与深度调压网络的模型输出维度相同。作为深度调压网络模型输入的可观测节点注入潮流矩阵与预测目标的关键节点电压量测值均可直接从调度中心的广域量测系统中直接取得，使得该模型可以有效的应用于实际电力系统中。

深度调压网络的具体网络结构如图 3.2 所示，深度调压网络主要包含 3 个卷积结构（如图中黑色虚线框所示）和两个全连接层。每个卷积结构又包括一个卷积层和一个批正则化层，根据潮流矩阵的数据结构与特点，在深度调压网络中并未加入池化层。卷积层作为特征提取器来提取潮流矩阵中的关键结构特征，全连接层实现高阶特征到节点电压之间的映射，批正则化层可以通过减少训练过程中数据分布的偏移有效加速训练过程并提高收敛效率。






图 3.2 深度调压网络具体结构与网络参数

根据潮流矩阵的数据结构与特点，深度调压函数选择了较大的卷积核。三个卷积层的卷积核大小分别为(2×9，2×7和2×7)，深度调压网络的感受野大小约为441，足以拟合大多数中等规模的配电网。对于节点数目更多的大规模配电网系统，可以适当调整卷积核大小以适应实际需求。

### 3.3 调压函数拟合的合理性解释

#### 3.3.1 潮流方程约束下节点电压与注入功率之间的关系

电力系统运行过程中，节点注入功率与节点电压之间需要满足潮流方程的约束，即

$$\begin{cases} P_i - U_i \sum_{j \in i} U_j (G_{ij} \cos \theta_{ij} + B_{ij} \sin \theta_{ij}) = 0 & i = 1, 2, \dots, N \\ Q_i - U_i \sum_{j \in i} U_j (G_{ij} \sin \theta_{ij} - B_{ij} \cos \theta_{ij}) = 0 & i = 1, 2, \dots, N \end{cases} \quad (3-4)$$

式中  $P_i$  和  $Q_i$  分别为节点  $i$  的有功注入功率和无功注入功率， $U_i$  为节点  $i$  的电压幅值， $\theta_{ij}$  为节点  $i$  和节点  $j$  之间的相角差， $G_{ij}$  和  $B_{ij}$  分别为节点  $i$  和节点  $j$  之间的电导和电纳。对于一个有  $n-r$  个 PQ 节点， $r$  个 PV 节点的电力系统，则共有  $n$  个有功偏差方程， $r$  个无功偏差方程。深度调压网络输入为潮流矩阵，输出为节点电压，因此可以将深度调压网络看作拟合的是从潮流方程的系数到潮流方程的解的函数

关系。在潮流方程约束下，电力系统的节点注入功率  $(\mathbf{P}, \mathbf{Q})$  和节点电压  $\mathbf{U}$  之间存在如下式所示的隐函数关系：

$$f(\mathbf{P}, \mathbf{Q}, \theta, \mathbf{U}) = \begin{bmatrix} f_p(\mathbf{P}, \theta, \mathbf{U})|_n \\ f_q(\mathbf{Q}, \theta, \mathbf{U})|_{n-r} \end{bmatrix} = 0 \quad (3-5)$$

其中  $f_p$  和  $f_q$  分别表示由有功偏差方程和无功偏差方程定义的函数关系，根据潮流方程可以经过简单的推导得到下式

$$\begin{aligned} \frac{\partial f}{\partial[\theta, \mathbf{U}]} &= \begin{bmatrix} \frac{\partial f_p}{\partial \mathbf{P}} \frac{\partial \mathbf{P}}{\partial \theta} & \frac{\partial f_p}{\partial \mathbf{P}} \frac{\partial \mathbf{P}}{\partial \mathbf{U}} \\ \frac{\partial f_q}{\partial \mathbf{Q}} \frac{\partial \mathbf{Q}}{\partial \theta} & \frac{\partial f_q}{\partial \mathbf{Q}} \frac{\partial \mathbf{Q}}{\partial \mathbf{U}} \end{bmatrix} \\ &= \begin{bmatrix} \mathbf{I}_n \times \frac{\partial \mathbf{P}}{\partial \theta} & \mathbf{I}_n \times \frac{\partial \mathbf{P}}{\partial \mathbf{U}} \\ \mathbf{I}_{n-r} \times \frac{\partial \mathbf{Q}}{\partial \theta} & \mathbf{I}_{n-r} \times \frac{\partial \mathbf{Q}}{\partial \mathbf{U}} \end{bmatrix} = \mathbf{J} \end{aligned} \quad (3-6)$$

即在潮流方程约束下的隐函数  $f(\mathbf{P}, \mathbf{Q}, \theta, \mathbf{U})$  对电压  $\mathbf{U}$  和相角  $\theta$  的偏导数即为潮流方程的雅可比矩阵  $\mathbf{J}$ 。在系统正常运行状态下，雅可比矩阵可逆。根据隐函数定理， $\partial f / \partial[\theta, \mathbf{U}]$  可逆，则存在从  $\mathbf{P}, \mathbf{Q}$  到  $\mathbf{U}$  的唯一的函数映射  $\psi: \mathbf{P}, \mathbf{Q} \rightarrow \mathbf{U}$ ，即

$$\mathbf{U} = \varphi(\mathbf{P}, \mathbf{Q}) \quad (3-7)$$

式(3-7)表示，在系统全观测条件下，节点注入功率与节点电压之间存在确定的非线性函数关系。

### 3.3.2 考虑出力相关性的调压函数拟合

如前文所述，在潮流方程约束下，系统全观测时，节点注入功率与节点电压之间存在确定的调压函数关系  $\varphi$ ，当系统所有节点出力已知时，各节点的电压由函数关系  $\varphi$  完全确定。然而对于通信系统约束下仅部分节点注入功率已知的低感知度配电网，理论上节点电压无法由函数关系  $\varphi$  完全确定。

然而如果考虑到在同一区域内，风电和光伏等新能源的出力具有一定的相关性，系统的全观测存在一定的信息冗余，那么对部分节点的出力观测其实可以在一定程度上表征系统整体的出力状态，使得深度调压网络在部分观测下的拟合调压函数关系成为可能。

我们用节点出力间的皮尔逊相关系数来衡量节点出力的相关性，皮尔逊相关系数定义如下：

$$\rho_{X,Y} = \frac{\text{cov}(X,Y)}{\sigma_X \sigma_Y} = \frac{E((X - \mu_X)(Y - \mu_Y))}{\sigma_X \sigma_Y} \quad (3-8)$$

为了能够更加直观的说明考虑节点出力相关性对调压函数拟合的影响, 本文采用一个简单的3节点系统作为算例进行说明。




图 3.3 三节点系统结构示意图

其中节点0为平衡节点, 节点1和节点2为PQ节点。设节点1为电压控制关键节点, 则可得

$$\dot{U}_1 = \dot{U}_0 - (R_1 + jX_1) \left( \frac{P_1 + jQ_1}{\dot{U}_1} + \frac{P_2 + jQ_2}{\dot{U}_2} \right)^* \quad (3-9)$$

设平衡节点电压为参考电压  $\dot{U}_0 = 1 \angle 0^\circ$ , 如果假设系统电压偏差不大, 且线路两端相角偏差较小, 则可忽略上式中的虚部部分, 得到:

$$U_1 \approx U_0 - [R_1(P_1 + P_2) + X_1(Q_1 + Q_2)] \quad (3-10)$$

在系统全观测时, 节点电压  $U_1$  可由节点注入功率和网络参数完全确定, 且线路阻抗固定时, 节点电压和节点注入功率成简单的线性关系。但是当系统部分可观测, 或者系统无法准确建模( $R, X$  未知)时, 则难以通过上式直接得到电压和节点注入功率之间的关系。不妨设节点1可观测, 节点2不可观测, 即  $\{N_1\} \in \mathcal{N}^0$ ,  $\{N_2\} \in \mathcal{N}^x$ 。在  $P_2$  和  $P_1$  的皮尔逊相关系数分别为 1、0.9、0.8 且节点出力功率因数固定时,  $U_1$  和  $P_1$  之间满足的关系如图 3.4 所示。

从图中可以看出, 当节点2和节点1的出力完全相关( $r=1$ )时, 关键节点电压  $U_1$  和关键节点出力  $P_1$  成线性关系; 当节点2和节点1出力满足一定的相关性时( $r=0.8, 0.9$ ),  $U_1$  在  $P_1$  的一个线性函数附近小范围内分布, 在此系统中拟合误差不超过 0.003, 这样的误差对于10%左右的电压偏差控制目标是完全可接受的。

算例结果表明, 在考虑分布式电源出力相关性的条件下, 对系统的全观测确实存在一定的信息冗余, 对系统的部分观测可以在一定程度上确定系统整体状态, 可以合理的假设可观测节点注入功率( $\mathbf{P}^0, \mathbf{Q}^0$ )到节点电压  $U$  之间存在确定的非线性调压函数关系, 在合理的网络结构设计和数据选择基础上深度调压网络可以拟

合得到调压函数关系  $U = \varphi(P^0, Q^0)$ 。




图 3.4 不同出力相关系数下关键节点电压与可观测节点出力间关系

### 3.3.3 深度调压网络对数据量的需求

如前文所述深度调压网络拟合的是潮流方程从系数到解的函数映射关系，如果我们考虑所有的映射是样本总体的话，那么系统正常的运行过程是一个天然的对样本总体的采样过程。很明显我们无法对样本总体完全采样，确定模型训练的数据量需求对模型的实际应用有重要意义。

在潮流方程约束下，节点出力与节点电压之间的非线性函数关系  $\varphi$  是连续可导且近似线性的平滑函数。如果用一个线性函数代替  $\varphi$  则可得

$$U = f(P, Q) = A \begin{bmatrix} P \\ Q \end{bmatrix} \quad (3-11)$$

其中  $A$  是线性系数矩阵，当节点出力矩阵可逆时，

$$A = U \begin{bmatrix} P \\ Q \end{bmatrix}^{-1} \quad (3-12)$$

因此在线性假设下，节点出力矩阵可逆即可确定函数关系。对于一个有  $n$  个节点的电力系统，仅需要  $2n$  个非线性相关的有效采样保证矩阵可逆。当然考虑到  $\varphi$  的非线性，以及部分观测条件下的出力相关性的拟合仍然需要更多的有效样本对深度调压网络进行训练。

### 3.4 算例分析

#### 3.4.1 算例系统介绍

我们用一个经过调整后的 IEEE33 节点系统模拟实际电力系统的运行情况。系统结构如图 3.5 所示




图 3.5 经过调整的 IEEE 33 节点系统

如图 3.5 所示，相比标准 IEEE 33 节点系统，本文所用算例系统加入了 8 个 DG，每个 DG 容量均为 1.125MW，并将系统中所有节点按照是否接入调度系统分为了可观测节点和不可观测节点。可观测节点在图中用实线表示，不可观测节点在图中用虚线表示。

为了符合中国电网的电压等级，算例中将系统的基准电压  $U_{base}$  调整为 10kV，并对应的调整了系统阻抗参数。不失一般性的，本文选择分布式光伏作为电源接入到算例系统中，并取冀北某地区分布式光伏出力实测数据与负荷实测数据作为算例进行分析。其中一个典型日分布式电源出力与负荷水平如图 3.6 所示。

从图中可以看出，由于系统电压水平较低，负荷曲线表现出力一定的商业负荷特性。每天负荷变化趋势较为相似，早晚负荷水平较低，中午负荷水平较高，最高负荷出现在 10:00~16:00 时间段内，且较为平缓。不同天的负荷曲线仅在细节上有一定差异。

分布式电源的出力曲线受到天气影响较大，且波动性较强。不同天的分布式光伏出力曲线差别较大。为满足模型训练的数据需求本文随机选择了 17 天的系统实测数据作为模型仿真输入，这 17 天的数据基本可以涵盖所有典型天气场景下的出力情况，以保证训练得到的深度调压网络的有效性。




图 3.6 分布式光伏与负荷的几个典型日出力曲线

### 3.4.2 深度调压网络训练细节与训练结果

在 matlab 下用仿真数据代替系统实际运行数据，取 17 天的仿真数据，24480 个点（每分钟一个点）作为模型训练的数据集。随机选择其中的 20000 个点作为训练集，其余 4480 个点作为测试集。

对于如图 3.5 所示的配电系统，深度调压网络以可观测节点潮流矩阵作为模型输入，即输入为一个维度为  $2 \times 17$  的矩阵。选择节点 2,14,20,27,18 作为关键节点，以其节点电压作为输出。为了加快深度调压网络的训练过程并使模型收敛更加稳定，对输入数据按照下式进行了归一化处理

$$P_0 Q_0' = \frac{P_0 Q_0 - \mu_{P_0 Q_0}}{\sigma_{P_0 Q_0}} \quad (3-13)$$

$$\hat{U}' = \frac{\hat{U} - \mu_{\hat{U}}}{\sigma_{\hat{U}}}$$

上式中  $P_0 Q_0$  为原始可观测节点潮流矩阵，维度为  $2 \times 17$ ， $\mu_{P_0 Q_0}$  和  $\sigma_{P_0 Q_0}$  分别为潮流矩阵的均值与方差， $P_0 Q_0'$  是经过归一化之后的可观测节点潮流矩阵，作为模型的输入， $\mu_{P_0 Q_0}$ ， $\sigma_{P_0 Q_0}$  和  $P_0 Q_0'$  维度均与  $P_0 Q_0$  一致。 $\hat{U}$  是关键节点电压实测矩阵（通过仿真计算得到），维度为  $1 \times 5$ ， $\mu_{\hat{U}}$  和  $\sigma_{\hat{U}}$  分别为电压实测矩阵的均值与方差， $\hat{U}'$  是经过归一化之后的电压实测矩阵，作为深度调压网络的预测目标。经过归一化之后的可观测节点潮流矩阵和关键节点电压实测矩阵中每一个元素的均值都为 0，方差都为 1，可以有效的使网络训练更加容易，加速深度调压网络的训练过程。

深度调压网络的训练在 pytorch 平台下进行，设置 batch size 为 8，选择 SGD

(Stochastic Gradient Descent, 随机梯度下降法) 作为优化求解算法对深度调压网络进行训练。设置训练过程的学习率为 0.0005, 训练轮数 (epoches) 为 40, 在训练过程中总共经过 100000 次迭代。为了验证卷积神经网络结构和全连接结构对调压函数拟合效果的差异, 我们将深度调压网络与简单的三层全连接网络进行对比, 在相同的训练数据和训练参数条件下, 二者的训练过程如图 3.7 所示。




图 3.7 深度调压网络与全连接网络训练过程

图中的蓝线表示的是在全连接网络的训练过程中损失函数的变化情况, 从图中可以很清晰的看出经过 40 轮的训练过程, 全连接网络并没有明显的收敛现象, 而深度调压网络在经过约 10000 次迭代, 4 轮训练之后可以较为稳定的收敛。并且最终的训练误差很小, 几乎为 0。训练结束时的测试误差约为 0.006, 小于 1%, 说明了深度调压网络网络结构对调压函数拟合的有效性。

### 3.4.3 网络结构对拟合结果的影响

针对深度调压网络本文对不同的网络结构也进行了大量试验, 主要针对深度调压网络中的批正则化层 (batch normalization layer, 用 bn 表示)、池化层 (pooling layer, 用 pooling 表示) 和 3 个卷积层的卷积核大小进行讨论。训练结果如表 3.1 所示, 表中深度调压网络的网络结构用卷积核大小加是否加入批正则化层和是否加入池化层表示, 如(9,7,7)+bn-pooling 表示深度调压网络的三个卷积层的卷积核大小分别为  $2 \times 9$ 、 $2 \times 7$ 、 $2 \times 7$ , 加批正则化层不加池化层的深度调压网络结构。全连接层均与图 3.1 和图 3.2 所示的结构一致, 输入的可观测节点潮流矩阵和作为标签的关键节点电压矩阵也均按照式(3-13)所示进行了归一化出力。训练参数均

与 3.4.2 所述一致，表 3.1 所示训练误差与电压偏差均为训练好的深度调压网络在测试集上得到的结果。

表 3.1 不同网络结构下深度调压网络的电压拟合结果

网络结构	损失函数(loss)	电压偏差(.pu)
(3,3,3)+bn-pooling	0.2261	1.43e-2
(5,5,5)+bn-pooling	0.0650	7.64e-3
<b>(9,7,7)+bn-pooling</b>	<b>0.0469</b>	<b>6.49e-3</b>
(11,9,9)+bn-pooling	0.0472	6.49e-3
(13,11,11)+bn-pooling	0.0598	7.34e-3
(9,7,7)-bn-pooling	0.0616	7.69e-3
(9,7,7)+bn+pooling	0.1348	1.10e-2

从表 3.1 中可以看出，随着卷积核的增大，深度调压网络的拟合结果逐渐变好，尤其当卷积核大小从(3,3,3)增大到(5,5,5)时，拟合精度有非常明显的提升，但是当卷积核大小增大到(9,7,7)之后，再增大卷积核大小至(11,9,9)拟合精度不再有明显提升，且进一步增大卷积核大小至(13,11,11)后拟合精度降低。说明对于调压函数拟合任务，深度调压网络的卷积核大小会影响感受野的大小并最终对电压拟合精度产生较大影响。由于配电网的馈线形式，无法对配电网进行明显分区，节点电压几乎会受到所有节点注入功率的影响，因此当感受野大小不足以覆盖整个配电网所有节点时，调压函数的拟合将会受到极大的影响。当感受野大小足够大之后，再进一步增大卷积核大小不会产生明显增益，并且过大的卷积核会使得深度调压网络网络参数增多，容易产生过拟合现象，因此需要更多的有效数据和计算资源对其进行训练。为了平衡节点电压拟合精度和数据需求以及计算复杂度之间的矛盾。最终如图 3.1 和图 3.2 所示的深度调压网络选择了(9,7,7)的卷积核大小。

池化层在计算机视觉任务可以有效的降低模型复杂度，提取图像中的关键信息，但是在调压函数拟合任务中，池化层的加入会降低节点电压的拟合精度。这可能是由于调压函数拟合是一个细粒度的拟合问题，池化层的加入可能会使得模型丢失电压拟合的关键信息，导致电压拟合精度的降低。同时作为输入的潮流矩阵维度要远低于计算机视觉任务中的图像矩阵，且深度调压网络的模型参数数量和模型复杂度也远小于传统卷积神经网络，因此没有必要加入池化层来降低模型复杂度。而批处理层相当于在训练的过程中对每层神经网络的输出均做了归一化处理从而解决了内部分布偏移问题（Internal Covariate Shift），可以使得模型收敛更加稳定，并在一定程度上加快训练速度，因此最终图 3.1 和图 3.2 所示的深度调压网络选择了加入批正则化层，并池化层的网络结构。



#### 3.4.4 训练数据量对拟合结果的影响

如前文 3.3.3 节对于一个有  $n$  个节点的电力系统，仅需要  $2n$  个有效数据便可完成模型训练，即对于图 3.5 所示的算例系统，仅需 66 个有效数据点即可，但是中低压配电网的强非线性，以及低感知状态下的数据相关性均使得我们需要更多的有效数据来训练深度调压网络。深度调压网络对训练数据的需求将影响其在实际系统中应用的可能性，因此本文在图 3.5 所示的算例系统中讨论了不同样本数目下的深度调压网络的训练时间与在测试集上的拟合误差，结果如表 3.2 所示。

表 3.2 不同训练数据量下深度调压网络的训练结果

训练数据天数	训练集 样本数	测试集 样本数	训练时间	电压偏差(.pu)
1	1000	440	2m56s	1.53e-2
3	3500	820	4m33s	1.24e-2
7	8000	2080	9m56s	8.86e-3
14	16000	4160	20m43s	6.72e-3
17	20000	4480	25m12s	6.49e-3
30	35000	8200	42m22s	6.41e-3

为了探究深度调压网络的电压拟合效果与样本数量之间的关系，我们分别在调整后的 IEEE 33 节点系统中进行了 1、3、7、14、17 和 30 天的仿真，将仿真数据作为数据集进行深度调压网络的训练，训练集和测试集的样本数划分、训练时间和训练结束后拟合的电压偏差见表 3.2。实验中的深度调压网络统一采用了 (9,7,7) 的卷积核大小和加入批正则化层去掉池化层的网络结构，并且输入数据均按照式(3-13)进行了归一化处理，实验过程中的优化器和参数设置均与 3.4.2 节相同。

训练过程与训练时间的统计均在 1 张英伟达 1080 TITAN GPU 上完成。从表 3.2 所示结果中可以看出，随着样本数目的不断增多，训练时间逐渐增加，并且拟合的电压偏差逐渐减小。当仅有 1 天和 3 天仿真数据作为训练样本时，由于训练数据难以覆盖所有典型的分布式光伏出力场景，因此出现了严重的过拟合现象，虽然训练误差很小但是测试误差较大（超过 0.01 pu）。样本数量达到 7 天以后，基本可以覆盖所有典型的分布式光伏出力场景（和样本选择有关）因此过拟合现象明显改善，电压拟合精度也有较大提升。当样本数量达到 14 天以后，样本数量的提升对精度的影响有限，但是会线性的增大训练时间。

实际应用过程中，需要寻找训练时间和预测精度之间的平衡，同时也要根据实际系统的节点数目和计算设备做出调整。根据本文实验所得结果半月左右的样本数量已经足够将模型训练到较高精度，更多的样本对精度影响不大，边际效应

明显。

除了样本数量之外，样本的选择同样对深度调压网络的拟合精度有较大影响，训练样本应该尽量包括所有分布式电源的典型出力场景，以满足训练数据与测试数据的独立同分布假设。想要将深度调压网络应用于实际系统中时，应特别注意训练数据的选择，以避免出现严重的过拟合问题。

### 3.4.5 系统感知度敏感性分析

为了探讨深度调压网络在实际系统中的可适用范围，本文以研究不同的系统观测率对深度调压网络拟合效果的影响为目的进行了一系列实验，结果如图 3.8 所示。实验仍然在图 3.5 所示的算例系统上进行。在图 3.5 所示的算例系统中，分别选择了系统可观测率为 100%、75%、50% 和 25% 几种情况进行了实验，即分别假设系统中的 33 个节点、24 个节点、17 个节点和 9 个节点接入到配电网调度系统中。可观测节点在系统中随机选择，并保证分布式电源接入节点按照比例划分。




图 3.8 不同系统观测率下深度调压网络的电压拟合效果

实验中的深度调压网络统一采用了(9,7,7)的卷积核大小和加入批正则化层去掉池化层的网络结构，全连接层参数按照输入矩阵大小进行了相应的调整，并且对输入数据均进行了归一化处理，实验过程中的优化器和参数设置均与 3.4.2 节相同。并且均以 17 天的仿真数据模拟系统实际运行数据作为数据集，其中的 20000 个样本作为训练集，4480 个样本点作为测试集，训练轮数均为 40 轮。在不同观测率下，深度调压网络的训练过程与在测试集上的电压拟合偏差如图 3.8 和表 3.3

所示。

表 3.3 不同观测率下深度调压网络拟合效果

系统观测率	可观测 节点数	不可观测 节点数	电压偏差(.pu)
100%	33	0	1.73e-3
75%	24	9	6.42e-3
50%	17	16	6.49e-3
25%	9	24	1.35e-2

从图 3.8 和表 3.3 可以看出,当系统可观测率为 100%时,深度调压网络收敛速度很快,且经过约 5 轮训练之后,在测试集上的拟合误差收敛到 0.001 pu,已经几乎为零。在一定程度上,说明了系统全部可观测条件下,节点电压和节点注入功率之间的调压函数关系真实存在,并且深度调压网络可以有效的通过历史运行数据拟合这一函数关系。

当系统观测率降低为 75%和 50%时,深度调压网络的收敛速度减慢,并且在测试集上的关键节点电压拟合误差也随之增大。经过 10 轮到 15 轮的训练模型逐渐收敛,最后关键节点电压拟合误差收敛到 0.006 pu 附近,这样的节点电压误差水平已经足以满足电压控制的需求。同样说明在满足分布式电源出力相关性假设条件下,节点电压和可观测节点注入功率之间的调压函数关系  $U = \varphi(P^0, Q^0)$  真实存在,并且深度调压网络可以通过历史运行数据对这一函数关系有效的进行拟合。另一个值得注意的现象就是在系统观测率为 75%和 50%时,二者的训练过程以及训练结束之后再测试集上的预测误差均十分相近,差别很小。这一现象在一定程度上说明了在分布式电源出力具有较强的相关性情况下对于系统的观测存在一定的信息冗余,50%观测下几乎包含 75%观测下所有的高阶信息,佐证了节点电压和可观测节点注入功率之间的调压函数关系  $U = \varphi(P^0, Q^0)$  存在的合理性。

当系统观测率降低到 25%时,深度调压网络在测试集上的拟合误差明显增大,一方面这是因为此时受到通信系统的限制,系统的观测已经丢失了大量重要信息,深度调压网络难以对调压函数进行有效拟合,另一方面随着输入潮流矩阵输入维度的降低,深度调压网络的参数数量也会随之减少(受到全连接层的影响),因此导致深度调压网络的表达能力下降。

实际应用中系统可观测率主要受到的是通信条件的限制,以实验结果来看,随着观测率的提高,深度调压网络的拟合精度也逐步提高,在我国目前观测率约为 50%的分布式电源接入下的配电系统中,深度调压网络的拟合精度已经基本可

以满足电压控制的需求。

### 3.5 本章小结

本章首先根据我国分布式电源当前阶段的发展条件，建立了考虑通信系统与建模精度限制下的低感知度配电网原型。然后设计了一个适应潮流数据特点的深度卷积神经网络——深度调压网络对调压函数进行拟合。深度调压网络以可观测节点注入潮流矩阵作为模型输入，以关键节点电压作为模型输出，用数据驱动的方法解决了通信系统下建模精度限制下对配电网关键节点电压的感知问题。并以潮流方程为基础在考虑分布式电源出力相关性的条件下讨论了调压函数拟合的合理性。最后以一个调整后的 IEEE 33 节点系统作为算例，以仿真数据代替系统实测数据验证了深度调压网络结构的有效性，主要结论总结如下：

1、对于调压函数拟合任务，针对潮流矩阵数据结构特点，具有卷积结构的深度调压网络效果优于简单的全连接网络。深度调压网络中的卷积层可以有效提取潮流矩阵中的关键信息，从而提高深度调压网络的拟合效率。

2、深度调压网络的卷积核大小、批正则化层和池化层会影响其在测试集上的拟合精度。卷积核的大小会决定深度调压网络感受野的大小，而配电网节点电压几乎会受到所有节点注入功率的影响，因此当感受野大小不足以覆盖整个配电网所有节点时，调压函数的拟合将会受到极大的影响。池化层会在模型内部丢降维过程中失重要信息导致精度降低，并不适合调压函数拟合任务。批正则化层可以有效提高模型收敛速度。最终深度调压网络选择了(9,7,7)的卷积核大小和加入批正则化层去掉池化层的网络结构。

3、数据集大小会影响深度调压网络拟合效果。更多的有效训练数据可以有效提升深度调压网络在测试集上的表现，但存在一定的边际效应，当数据集大小达到 15 天以后，增大数据集对模型表现提升有限，训练时间却会线性增加。因此实际应用中既需考虑样本采集的条件限制，也应平衡拟合精度与计算时间之间的矛盾。

4、当系统观测率为 100%，深度调压网络可以以极高的精度拟合节点电压。系统观测率降低为 75 和 50% 时，也可达到较高拟合精度，足以满足调压需求，且二者训练过程和最终结果相差不大，说明了可观测节点注入功率与关键节点电压之间的调压函数关系确实存在。系统观测率降至 25% 时，电压拟合精度明显降低，因此实际应用中应保证深度调压网络的观测率在 50% 以上。

## 第4章 基于深度调压网络的含高比例DG的配电网电压控制

### 4.1 本章概述

分布式电源接入后导致的配电网电压沿线电压分布差异大，合理利用分布式电源的无功调节能力可以有效限制过电压，提高系统运行稳定性。如前文所述，目前常见的配电网集中式电压控制需要配电网中的无功源统一接入调度中心，对配电网的通信系统有较高要求。并且传统电压控制方法依赖于通过精确的潮流模型得到的无功电压灵敏度，因此难以有效应用于受到通信系统与建模精度限制的低感知度配电网。

本章针对以上问题，提出一种适用于低感知度配电网的集中式电压控制模型。配电网电压控制的主要目的是防止系统过电压，并使得节点电压满足特定的电压曲线。因此本章提出的电压控制模型以关键节点电压与参考值的偏差为优化目标，以系统中的连续调节设备如分布式电源逆变器的无功出力为控制变量，通过控制关键节点电压在参考值附近来实现系统的电压控制，增大系统的电压裕度并提高系统稳定性。本文第 3 章用深度调压网络以数据驱动的方式解决了低感知度配电网的调压函数拟合问题。电压控制模型中可以用深度调压网络拟合得到的函数关系代替无功电压灵敏度，用梯度下降法对模型进行求解。控制梯度可以直接通过梯度回传得到，无需系统的潮流模型，从而实现适用于低感知度配电网的无模型的电压控制。

本章第 2 节首先介绍了基于潮流模型的集中式电压控制方法应用在低感知度配电网中的局限性。然后在第 3 节以此为基础提出了改进的适用于低感知配电网的集中式电压控制模型。第 4 节提出了基于深度调压网络对低感知度配电网集中式电压控制模型的求解方法，总结了电压控制流程。第 5 节以加入分布式电源的 IEEE 33 节点系统作为算例验证了所提电压控制方法的有效性。

### 4.2 基于潮流模型的电压控制方法的局限性

如前文所述，传统二级电压控制数学模型如式(2-5)所示。二级电压控制模型以先导节点电压与参考电压的偏差作为优化目标，以控制发电机无功调整量为控制变量，考虑了关键节点电压的上下限约束和控制发电机无功容量约束。控制发电机无功出力与节点电压之间的关系用无功电压灵敏度矩阵简化，使得该模型为一个凸优化问题，可以方便的进行求解。

然而直接将(2-5)所示的二级电压控制模型应用于低感知度配电网集中式电压控制中主要有以下几个问题：

(1) 配电网通常呈馈线结构，难以对其进行有效的分区。相比较高压输电网，中低压配电网各个节点之间的联系更为紧密，节点电压几乎受到所有节点注入功率的影响，因此难以像高压输电网一样分为几个近似互不影响区域。

(2) 先导节点难以有效选择。分布式电源的接入使得配电网电压波动增大，难以像高压输电网一样选择有代表性的节点作为先导节点。

(3) 中低压配电网的参数杂散性很强，并且分布式电源的电力电子接口使得节点电压和注入功率之间非线性关系很强。将潮流方程进行线性化简化得到的无功电压灵敏度矩阵无法完全适用于配电网。

(4) 由于目前我国中低压配电网通信系统建设水平较低，且在调度系统中的建模精度差，配电网整体仍处于“低感知度”状态。因此很难直接在潮流模型中计算无功电压灵敏度。并且配电网的低四遥率使得我们几乎无法获得配电系统完整的潮流模型。

### 4.3 适用于低感知度配电网的集中式电压控制模型

为了解决 4.2 节中二级电压控制模型直接应用于低感知度配电网存在的问题，根据低感知度配电网的特点与第 3 章提出的深度调压网络，将适用于低感知度配电网的电压控制模型改写如下：

$$\begin{aligned} \min_{\mathbf{Q}_{DG}^0} F_u &= \sum_{N_i \in \mathcal{N}_k^0} \left( U_i^{ref} - \hat{U}_i - \Delta \varphi_i(\mathbf{P}^0, \mathbf{Q}^0) \right)^2 \\ s.t. \quad &U_i^{\min} \leq \varphi_i(\mathbf{P}^0, \mathbf{Q}^0) \leq U_i^{\max} \\ &(Q_{DG_i} + \Delta Q_{DG_i})^2 + (P_{DG_i} + \Delta P_{DG_i})^2 \leq S_{DG_i}^{\max} \end{aligned} \quad (4-1)$$

式中  $\mathcal{N}_k^0$  表示的是关键节点集合，对于关键节点的选择规则见后文详述； $U_i^{ref}$  是关键节点电压参考值， $\hat{U}_i$  是关键节点电压实测值； $\mathbf{P}^0, \mathbf{Q}^0$  与前文定义一致，分别是可观测节点有功注入功率和无功注入功率集合； $\varphi_i$  表示的是可观测节点注入功率到关键节点电压之间的调压函数关系，由深度调压网络根据系统历史运行数据进行拟合； $U_i^{\min}$  和  $U_i^{\max}$  分别表示关键节点电压的上下限； $Q_{DG_i}$  和  $P_{DG_i}$  分别表示第  $i$  个分布式电源的有功出力和无功出力， $S_{DG_i}^{\max}$  表示第  $i$  个分布式电源变流器的容量限制； $\Delta Q_{DG_i}$  和  $\Delta P_{DG_i}$  分别表示第  $i$  个分布式电源的有功调节量和无功调节量。

相比式(2-5)所示的电压控制模型，式(4-1)所示模型针对低感知度配电网的特点做出了如下一些调整：

(1) 选择可观测分布式电源并网点和电网末端节点作为关键节点  $\mathcal{N}_k^0$ 。分布式电源并网点通常较为均匀的分布在系统中，分布式电源并网点电压可以在一定程度上代表系统整体电压水平。而分布式电源并网点电压越限有可能导致分布式电源脱网事故，从而引发连锁反应导致更加严重的稳定问题，保证分布式电源并网点电压不越限有重要意义。在分布式电源出力较大引起潮流倒送导致系统过电压的情景下（电压越上限），分布式电源并网点电压通常为电压最高的节点；而在分布式电源出力较小，负荷较重导致系统电压越下限的情境下，电网末端节点电压通常为全网最低。因此选择可观测分布式电源并网点和电网末端节点作为关键节点代替先导节点进行电压控制。

(2) 以关键节点电压与参考值偏差为优化目标，以分布式电源无功注入功率为控制手段。虽然分布式电源的接入使得系统电压波动性增强，给电压控制变得更加困难，与此同时分布式电源逆变器的无功调节能力也给配电网带来了优质的无功源。分布式电源逆变器的无功出力可以连续调节，在无容量约束条件下基本和有功出力解耦，且基本无调节成本，是非常优质的无功源。模型主要关注的分布式电源的无功调节能力，并未考虑并联电容器（SC）、有载调压变压器（OLTC）等其他无功调节设备，这些设备可以待分布式电源无功容量用尽后，采用传统调节方式，配合分布式电源一同进行电压控制。

(3) 用深度调压网络拟合的调压函数关系  $\varphi_i$  代替无功电压灵敏度矩阵。深度调压网络可以利用系统历史运行数据拟合可观测节点注入功率与关键节点电压之间的非线性函数关系，且并不依赖于精确的潮流模型，可以有效应用于低感知度配电网中。

(4) 为了最大化分布式电源的无功调节能力，式(4-1)模型中仅考虑了分布式电源逆变器的容量限制而没有考虑功率因数限制。实际运行过程中，分布式电源逆变器的无功出力和有功出力几乎解耦，因此除容量限制外并无其他约束。

## 4.4 基于深度调压网络的电压控制方法

### 4.4.1 基于梯度下降的集中式电压控制

由于如式(4-1)所示的适用于低感知度配电网的集中式电压控制模型中用深度调压网络拟合的调压函数关系  $\varphi_i$  为一个非线性函数关系，因此该模型为一个非凸优化问题，难以直接求解。对于这类优化问题，可以直接采用梯度下降法得到近似最优解。目前已有相关采用梯度法对电压控制模型进行求解，这种方法首先计算优化目标对节点注入功率的梯度，如式(4-2)所示

$$\begin{aligned} g_Q &= \frac{\partial F_u}{\partial \mathbf{Q}_{DG}^0} \\ g_P &= \frac{\partial F_u}{\partial \mathbf{P}_{DG}^0} \end{aligned} \quad (4-2)$$

其中  $F_u$  是电压控制模型的优化目标，由(3-3)定义， $\mathbf{Q}^0$  和  $\mathbf{P}^0$  分别是可观测节点无功注入功率和有功注入功率的集合， $g_Q$  和  $g_P$  分别是优化目标函数对无功注入功率和有功注入功率的梯度。

式(2-5)所示的传统集中式电压控制模型中，无功电压灵敏度矩阵即为在已知潮流模型条件下优化目标对控制节点无功注入功率的梯度矩阵（雅可比矩阵）。在低感知度配电网电压控制模型中用深度调压网络拟合调压函数，当深度调压网络训练完毕后，可以将其参数固定，然后根据式(4-2)计算优化目标并采用 BP 算法进行梯度回传，可以直接得到优化目标对节点注入功率的梯度  $g_Q$  和  $g_P$ 。

求得优化目标对可观测节点无功注入功率和有功注入功率之后，在指令周期内进行梯度下降，如下式所示：

$$\begin{aligned} \mathbf{Q}_{DG}^0(k+1) &= \mathbf{Q}_{DG}^0(k) - \lambda \times g_Q \\ \mathbf{P}_{DG}^0(k+1) &= \mathbf{P}_{DG}^0(k) - \lambda \times g_P \end{aligned} \quad (4-3)$$

其中  $\mathbf{Q}_{DG}^0(k)$  和  $\mathbf{Q}_{DG}^0(k+1)$  分别是第  $k$  个指令周期和第  $k+1$  个指令周期可观测分布式电源（可控无功源）的无功注入功率， $\mathbf{P}_{DG}^0(k)$  和  $\mathbf{P}_{DG}^0(k+1)$  分别是第  $k$  个指令周期和第  $k+1$  个指令周期可观测分布式电源（可控有功源）的有功注入功率， $\lambda$  是更新步长。

#### 4.4.2 电压控制流程

采用如式(4-3)所示的梯度下降法进行电压控制最关键的一步是计算得到优化目标对节点注入功率的梯度。如前文所述，基于深度调压网络的集中式电压控制方法，可以将在系统历史运行数据上预训练训练好的深度调压网络参数固定，然后计算优化目标函数并进行梯度回传，得到  $g_Q$  和  $g_P$ 。

因此基于深度调压网络的集中式电压控制可以主要分为两个步骤——离线深度调压网络模型训练和在线关键节点电压控制，整体示意图如图 4.1 所示。离线训练部分主要是收集有效的系统历史运行数据，并进行相应的预处理，利用式(3-3)计算相应的损失函数，进行梯度回传，利用优化求解算法更新深度调压网络参数，对其进行训练。在离线深度调压网络模型训练过程中深度调压网络参数可变，是采用梯度下降进行优化的对象，在图 4.1 中用虚线表示。

当深度调压网络离线训练完毕之后可以直接将网络参数拷贝并复制到调度系



统中进行在线的电压控制。在线控制过程中首先调度系统收集通信系统反馈回的可观测节点潮流矩阵，并对其进行统一的归一化处理。然后正向传播计算当前状态下关键节点电压的预测值，根据式(4-1)计算电压控制目标函数，然后进行反向传播，计算目标函数对节点注入潮流矩阵的梯度。在此过程中深度调压网络的参数固定并不进行参数更新，在图 4.1 中用实线表示。而节点潮流矩阵则需要根据计算得到的梯度按照式(4-3)进行更新，在图中用虚线表示。




图 4.1 低感知度配电网集中式电压控制示意图

基于深度调压网络的适用于低感知度配电网的集中式电压控制方法整体流程图如图 4.2 所示，主要包括以下步骤：

（1）电压控制动作触发。在调度系统中通常会按照下式设置一定的无功动作死区，

$$(1-\gamma)U_k^{ref} \leq \hat{U}_k \leq (1+\gamma)U_k^{ref} \quad (4-4)$$

其中  $U_k^{ref}$  是关键节点参考值， $\hat{U}_k$  是关键节点电压实测值， $\gamma$  是缓冲系数，当关键节点电压与参考值的偏差在动作死区内时这一动作周期不进行无功调节。根据文献[23]，设置缓冲系数为 0.01，即当关键节点电压实测值在  $0.99U_k^{ref} \sim 1.01U_k^{ref}$  范围内时此动作周期内不动作。

（2）导入离线深度调压网络，校验模型精度。调度系统导入预训练好的深度调压网络模型，考虑到随着时间推移，配电网网络结构和支路参数可能发生变化且数据分布也可能和模型训练过程中离线采样的数据集分布不同，导致模型失效，因此在使用深度调压网络进行电压控制之前需要对其进行精度校验，校验方式如下式所示：

$$\begin{aligned} \|\varphi(\mathbf{P}^0, \mathbf{Q}^0) - \hat{U}\|_{\infty} &< \varepsilon \\ \max_i |\varphi_i(\mathbf{P}^0, \mathbf{Q}^0) - \hat{U}_i| &< \varepsilon \end{aligned} \quad (4-5)$$

其中  $\varphi(\mathbf{P}^0, \mathbf{Q}^0)$  表示深度调压网络拟合得到的调压函数，其输出维度为  $1 \times m$ ， $m$  为关键节点个数， $\hat{U}$  为关键节点实测电压向量， $\varepsilon$  是一个设定的校核阈值取为 0.01。用深度调压网络的预测向量与实测向量的无穷范数衡量深度调压网络的拟合精度，即当深度调压网络最大的预测误差不超过 0.01 时，校核通过可以进行下一步电压控制，否则重新采集最新运行数据作为训练集训练新的深度调压网络。




图 4.2 适用于低感知度配电网的集中式电压控制流程图

(3) 获得优化目标对节点注入功率的梯度。首先正向传播计算当前状态下关键节点电压的预测值，根据式(4-1)计算电压控制目标函数，然后利用反向传播算法，计算目标函数对节点注入潮流矩阵的梯度。

(4) 调整可观测分布式电源出力。得到目标函数对注入潮流的梯度后，便可按照式(4-3)采用梯度下降法进行电压控制。为了保证新能源的消纳率，减少弃风弃光现象。分布式电源的功率调整采用“先无功后有功”，即在有无功容量时，优先调整无功容量，无功容量用尽后再采用有功缩减等策略进行电压控制。

(5) 下发本周期电压控制指令。

#### 4.4.3 关键节点的参考值设置

配电网的无功电压控制一方面要使得节点电压尽量满足设定的电压曲线，保证电压不越限，有较大的无功裕度。另一方面也要使得系统运行在一个相对经济的状态下。可以用有功网损  $P_{loss}$  衡量系统经济运行的指标，可以通过控制关键节点的参考电压  $U_k^{ref}$  来实现系统经济性优化，即在保证节点电压不越限的条件下使得有功网损最小。

节点  $i$  和节点  $j$  之间的电流可用下式计算：

$$I_{ij} = (U_i \angle \theta_i - U_j \angle \theta_j)(G_{ij} + jB_{ij}) \quad (4-6)$$

其中  $U_i$  和  $U_j$  分别是节点  $i$  和节点  $j$  的电压幅值， $\theta_i$  和  $\theta_j$  分别是节点  $i$  和节点  $j$  的电压相角， $G_{ij}$  和  $B_{ij}$  分别是支路  $ij$  的电导和电纳， $I_{ij}$  是节点  $i$  流向节点  $j$  的电流。可得支路  $ij$  上的损失功率  $S_{lossij}$  为：

$$\begin{aligned} S_{lossij} &= (U_i \angle \theta_i - U_j \angle \theta_j) I_{ij}^* \\ &= (U_i \angle \theta_i - U_j \angle \theta_j)(U_i \angle -\theta_i - U_j \angle -\theta_j)(G_{ij} - jB_{ij}) \\ &= (U_i^2 + U_j^2 - 2U_i U_j \cos(\theta_i - \theta_j))(G_{ij} - jB_{ij}) \end{aligned} \quad (4-7)$$

考虑相邻节点电压相角差通常较小，即  $\cos(\theta_i - \theta_j) = 1$ ，则节点  $i$  和节点  $j$  有功功率损失为：

$$P_{lossij} \approx G_{ij}(U_i - U_j)^2 \quad (4-8)$$

系统总的网损如下式所示：

$$P_{loss} = \sum_{i=1}^{N-1} \sum_{j=i+1}^N G_{ij}(U_i - U_j)^2 \quad (4-9)$$

由上式可知，在全网有统一的电压时，系统网损最小，因此可以设所有关键节点电压同为 1 以保证系统经济性，即：

$$U^{ref} = 1 \quad (4-10)$$

$$F_u = \sum_{i=1}^N \frac{1}{2}(1 - U_i)^2 \quad (4-11)$$

## 4.5 算例分析

### 4.5.1 潮流倒送引起的电压越限现象

同样采用如图 3.5 所示的加入分布式电源的 IEEE 33 节点系统作为仿真算例进行算例分析。如前文所述，为了适应我国配电网电压等级，算例中将系统的基准电压  $U_{base}$  调整为 10kV，并对应的调整了系统阻抗参数。

选择算例系统中的节点 1 至节点 18 这一馈线结构来研究不同渗透率条件下分布式电源对配电系统节点电压的影响，设置节点 1 为无穷大节点，代表变压器低压侧。当算例系统中的分布式电源出力分别为 0MW、0.5MW、1MW 和 1.5MW 时（所有分布式电源出力相等），节点 1 至节点 18 的电压曲线如图 4.3 所示，根据国电电网公司相关规定，35kV 配电网电压正负偏差之和不超过 10%，10kV 配电网电压合格范围为 0.93~1.07，图中虚线表示节点电压上下限。

从图中可以看出，当分布式电源出力为 0MW 时，与无分布式电源接入的传统配电网并无差别。潮流单向流动，从变压器低压侧流向电网末端，节点电压沿着潮流方向从节点 1 到节点 18 逐渐降低。此时电网末端节点（节点 18）为电压最低点，变压器低压侧（节点 1）为电压最高点，因此在无分布式电源接入的传统配电网系统中，仅需控制电网首末端节点便可保证全网电压不越限。




图 4.3 不同 DG 出力条件下节点电压曲线

当分布式电源出力增大为 0.5MW 时，分布式电源有功出力可以抵消掉一部分的负荷，因此从变压器流向电网末端的有功减少，沿馈线方向压降减少，节点电

压抬升，电压越限风险降低，系统电压条件得到有效改善。

分布式电源出力继续增大到 1MW 时，潮流倒送现象出现，分布式电源总的有功出力大于系统总负荷。分布式电源除了可以满足负荷用电需求外，还可通过变压器外送部分有功功率。由于潮流倒送现象，此时传统配电网电压沿馈线方向逐渐降低的结论不再成立，部分临近电网末端的节点电压已经高于变压器低压侧节点，因此传统配电网中仅通过控制配电网首末端节点不越限的方法已经无法有效适用。

当分布式电源出力增大到 1.5MW 时，潮流倒送的现象非常明显，分布式电源有功出力除了满足系统负荷用电需求外，还有大量的有功功率需要通过馈线外送到高压主网架。此时潮流流向几乎与传统配电网相反，有功潮流从电网末端流向变压器低压侧，因此从节点 1 到节点 18 的节点电压几乎为逐渐升高的趋势，并且由于潮流倒送导致的节点电压升高，电网末端已经有部分节点出现了越上限的情况，在此情况下传统配电网通过控制首节点不越上限，末节点不越下限的电压控制方法已经完全失效。




图 4.4 DG 加入前后系统节点电压分布

在一个如图 3.6 (a)所示的典型日情况下，没有分布式电源接入和有分布式电源接入情况下的统计一天所有节点的电压分布如图 4.4 所示。从图中可以看出在分布式电源接入之前，节点电压分布主要有两个峰，分别由白天负荷较重和夜晚负荷较轻的两个典型系统运行场景导致。节点电压主要分布在 0.92~1.02 之间。分

布式电源接入后，由于白天负荷较重时分布式电源出力抵消了部分负荷，因此系统欠电压现象有所改善，0.95 附近的分布峰值有所减小。同时分布式电源的接入使得系统整体电压得到抬升，1.0 附近的峰值有所增大。由于潮流倒送现象，节点电压分布范围明显增大，电压分布在 0.92~1.06 之间。尤其是电网末端节点，在分布式电源出力较小且负荷较重时电压全网最低容易电压容易越下限，分布式电源出力较大且负荷较轻时节点电压全网最高，又容易出现过电压风险。

分布式电源的接入不仅会使得配电网电压波动性增强，而且会使得节点电压分布范围增大，过电压风险和欠电压风险同时存在，使得配电网的电压控制更加困难。

#### 4.5.2 不同电压控制方法下的电压曲线

在如图 3.5 所示的低感知度配电网系统中，由于通信系统和建模精度的限制。传统的集中式电压控制方法和常用的分布式电压控制方法均无法有效应用。除了本文所提出的适用于低感知度配电网的电压控制方法外，只有就地控制策略可以有效应用。

在图 3.5 所示的算例系统中研究了本文所提电压控制方法和目前应用最广泛的就地式的 QV 下垂控制策略（其他就地下垂控制策略控制效果差别不大）的区别。

如前文所述，我们选择可观测分布式电源并网点和电网末端节点作为关键节点进行电压控制，即选择了节点 2,14,20,27,18 作为关键节点。然后在历史运行数据上对如图 3.1 所示的深度调压网络进行离线训练。得到预训练好的深度调压网络后，按照图 4.2 所示流程对算例系统进行电压控制。电压控制过程中设置指令周期为 5 分钟，更新步长  $\lambda$  为 0.1。系统电压上下限分别设置为 0.93 和 1.07。所有节点的参考电压按照 4.4.3 节所述设置为 1.0。算例系统中的高压输电网用一个采用二级电压控制的 IEEE 39 节点系统代替。

QV 下垂控制方法中设置可观测分布式电源并网点作为控制节点，对于控制节点  $i$  按照下式设置无功调节量

$$\Delta Q_i = \begin{cases} 0 & \text{if } |\hat{U}_i - U^{ref}| \leq 0.01 \\ -\alpha(\hat{U}_i - U^{ref}) & \text{else} \end{cases} \quad (4-12)$$

其中  $\Delta Q_i$  是可观测分布式电源并网点  $i$  的注入功率调节量， $\hat{U}_i$  是节点  $i$  的电压实测值， $U^{ref}$  是参考电压，同样设置为 1.0。 $\alpha$  是下垂系数，设置为 0.2。即如果当前周期节点  $i$  的电压实测值与参考值偏差小于 0.01，则不进行无功调节。否则按照

电压偏差的线性函数设置无功调节量。这种电压控制方式无需节点接入到调度系统中，也不需要系统精确的潮流模型，仅以节点电压实测值作为控制输入，因此可以有效应用于低感知配电网中。




图 4.5 不同控制方式下可观测 DG 节点电压曲线

在图 3.5 所示的算例系统中不采用任何电压控制手段、采用 QV 下垂控制和采用本文所提电压控制方法得到的几个可观测分布式电源并网点的电压曲线分别如图 4.5 所示。从图中可以看出，当不采取任何电压控制措施的情况下，节点电压的波动范围很大，分布式电源出力较小时有欠电压风险，分布式电源出力较大时又有过电压风险。并且越靠近电网末端的节点（节点 14）电压波动范围越大，靠近变压器低压侧的节点与变压器电气距离较近受到高压输电网的影响更大，因此电压始终保持在 1.0 附近。

QV 下垂控制和本文所提电压控制方法通过无功的调节作用，可以有效改善电压曲线，使得节点电压分布在 1.0 附近，尤其对电网末端节点改善更加明显。可以有效提高系统电压裕度，增强系统稳定性。并且，本文所提电压控制方法相比 QV 下垂控制节点电压更加靠近设定的电压曲线，保证全网电压统一，控制效果更好。

### 4.5.3 不同电压控制方法下的节点电压分布

对于如图 3.5 所示的算例系统中不采用任何电压控制手段、采用如前文所述的 QV 下垂控制和采用本文所提电压控制方法得到的关键节点（节点 2、14、20、27、18）的电压分布如图 4.6 所示。




图 4.6 不同控制方法下的关键节点电压分布

从图中可以清晰的看出未采用任何电压控制的节点电压分布范围很大，同时有过电压风险和欠电压风险，系统电压裕度较小，电压稳定性较差。如果因为电压越限导致某些分布式电源脱网，系统电压状态可能进一步恶化，形成连锁反应，导致非常严重的电压稳定问题。



在系统中采用简单的 QV 下垂控制策略可以有效的改善系统运行电压状态，节点电压分布范围明显缩小，主要分布在 0.96~1.03 范围内。已经几乎不会出现节点电压越限的情况，系统电压稳定性得到明显提高。

而采用本文所提电压控制方法可以有效的协调系统中的各类无功调节资源，达到全网最优，因此采用本文方法得到的关键节点电压分布最为集中，主要在 0.98~1.02 范围内，所有节点电压都主要分布在参考值附近，没有出现任何的电压越限现象，并且满足系统具有统一的电压。此时系统的电压裕度最高，并运行在相对经济的状态下。

在 QV 下垂控制和本文所提控制方法下，关键节点电压分布均近似为正态分布，正态分布的均值和方差如表 4.1 所示，从表中可以看出，相比较 QV 下垂控制，本文所提方法得到的电压分布均值更接近于参考电压，且方差更小。因此相比较 QV 下垂电压控制方法，采用本文所提的基于深度调压网络的适用于低感知配电网的集中式电压控制方法可以得到更好的电压控制效果。

表 4.1 关键节点电压分布的均值和方差

	均值	方差
QV 下垂控制	0.9922	0.0135
本文所提方法	0.9996	0.0057

在算例系统中不采用任何电压控制手段、采用如前文所述的 QV 下垂控制和采用本文所提电压控制方法得到的系统所有节点的电压分布如图 4.7 所示。




图 4.7 不同控制方法下的所有节点电压分布

与图 4.6 中关键节点的电压分布相比，图 4.7 所示的所有节点的电压分布除了因为统计节点数目增多导致的频数增大外，节点电压的分布形式与关键参数并

无明显区别。

在无任何电压控制手段下得到的关键节点电压和所有节点的电压分布均类似于混合高斯分布。而在 QV 下垂控制和本文所提电压控制方法下所有节点的电压分布均近似为正态分布，二者的均值和方差如表 4.2 所示。

表 4.2 所有节点电压分布的均值和方差

	均值	方差
QV 下垂控制	0.995	0.0125
本文所提方法	0.9994	0.0055

与表 4.1 相比，在不同的控制策略下，关键节点和所有节点的电压分布的均值和方差均差别不大。这在一定程度上说明了选择可观测分布式电源并网点和电网末端节点作为关键节点可以用关键节点电压代表系统整体的电压水平。通过仅控制关键节点的电压既可以改善系统电压状态又可以平衡其与计算复杂之间的矛盾。

#### 4.5.4 不同电压控制方法下的网损对比

在图 3.5 所示的算例系统中不采用任何电压控制手段、采用 QV 下垂控制策略和采用本文所提电压控制方法的系统网损如图 4.8 所示。

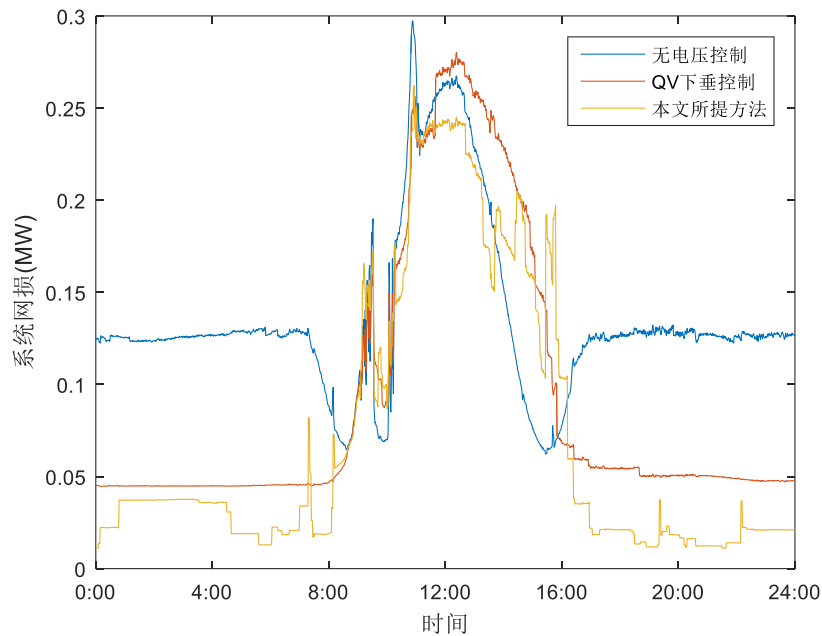


图 4.8 不同控制方法下的系统网损对比

从图中可以看出，当不采取任何控制手段时，系统网损整体处于较高水平，但也会随着负荷和分布式电源出力波动而变化。中午分布式电源出力较大的情况

下, 由于潮流倒送功率较大, 因此系统网损明显增大。采用下垂控制措施和本文所提电压控制方法可以有效减少系统网损。中午附近, 由于分布式电源大发, 潮流倒送功率较大, 因此所有控制策略下系统网损均处于较高水平, 电压控制手段对系统经济性改善不大。但是在每天 8:00 之前和 16:00 之后, 通过系统的无功调节手段可以有效的降低系统网损, 使得系统运行在更为经济的状态下。并且此时负荷和分布式电源出力均处于较低水平, 系统中流过的潮流较小, 节点电压之间相角差小。相比 QV 下垂控制, 本文所提方法通过控制系统满足统一电压可以更有效的降低有功网损, 进一步提高系统经济性。

无电压控制、QV 下垂控制和本文所提电压控制策略下的系统网损分别为 2.82 MWh, 1.76 MWh 和 1.28 MWh。相比其他两种方法本文提出的集中式电压控制方法网损分别降低 54.61% 和 27.3%。

#### 4.6 本章小结

针对受到通信系统和建模精度限制的低感知配电网, 本章以深度调压网络为基础提出了适用于低感知度配电网的集中式电压控制方法。所提方法以关键节点电压与参考值的偏差作为优化目标, 可观测分布式电源出力作为控制变量, 通过控制关键节点电压实现对全网电压的控制。本章首先讨论了传统基于潮流模型的集中式电压控制模型应用于低感知度配电网中的局限性。然后根据低感知度配电网的特点, 以第二章设计的深度调压网络为基础提出了适用于低感知度配电网的集中式电压控制数学模型, 该模型用深度调压网络拟合得到的函数关系代替了传统方法中的无功电压灵敏度矩阵, 用数据驱动的方法解决了通信系统和建模精度对集中式电压控制方法的限制。然后将梯度下降法和深度调压网络相结合提出了电压控制模型的求解方法, 明确了基于深度调压网络的低感知配电网集中式电压控制具体流程。最后用调整后的 IEEE 33 节点系统作为仿真算例验证了本文所提方法的有效性, 具体结论如下:

- 1、分布式电源接入可能会导致系统发生潮流倒送现象。使得电网电压波动性变强, 波动范围变大。尤其是电网末端节点, 既有电压越上限和又有电压越下限的风险, 传统配电网控制首末端节点电压不越限的方法失效, 使得配电网电压控制变得更加困难。

- 2、QV 下垂控制和本文所提集中式电压控制方法均可有效改善系统电压水平, 增大系统电压裕度, 提高系统电压稳定性。相比较就地的 QV 下垂控制, 本文所提的集中式电压控制方法可以更有效的协调系统中的各类无功调节资源, 达到全网最优, 电压曲线更加接近于参考值附近。

3、在 QV 下垂控制和本文所提方法控制下，关键节点电压分布近似为正态分布，在 QV 下垂控制下，均值和方差分别为 0.9922 和 0.0135，本文所提控制方法下，均值和方差分别为 0.9994 和 0.0057。在本文所提方法控制下，关键节点电压均值更靠近参考电压，且方差更小，能够得到更好的控制效果。

4、在 QV 下垂控制和本文所提方法控制下，系统所有节点的电压分布也近似为正态分布，且分布的均值和方差与关键节点电压分布差异很小。说明了用关键节点电压代表系统整体电压水平的有效性，且通过控制关键节点电压可以有效控制系统整体电压。

## 第5章 基于深度强化学习的配电网连续无功优化

### 5.1 本章概述

第4章提出的电压控制模型仅考虑了单时间断面下的配电网电压优化。然而，与负荷相比，DG的波动性更强，在十几分钟内就可能发生从满发到零出力的变化，导致无功调节设备需要反复动作。考虑负荷与DG波动，利用系统中的离散无功调节资源，在多时间断面下进行连续无功优化可以有效提高系统经济性。离散设备的动作次数约束使得配电网的连续无功优化是一个多时空、强耦合的复杂的非线性混合整数规划问题，难以直接求解。如前文所述，目前常用的无功优化模型多采用分段法完成时间上的解耦，从而实现对模型的化简。然而，这种分段方法难以有效应用于有DG接入的强波动性场景。同时，传统无功优化模型多依赖于精确的潮流方程作为优化模型的约束条件，也难以适用于低感知度配电网。

针对以上问题，本章提出一种适用于低感知度配电网的多时间断面下的连续无功优化模型。该模型将传统配电网的无功优化问题转化为一个马尔科夫决策过程，以最大化累积奖励为控制目标，以并联电容器为代表的离散无功调节设备的投切指令为控制变量，实现系统的无功优化。用一个深度神经网络直接拟合系统状态到离散无功调节设备的投切动作的函数关系，并采用深度强化学习算法对模型进行训练。训练完毕的神经网络以系统观测状态作为输入，以投切指令作为输出，可以实现实时决策，无需进行分段，也不依赖于负荷与DG出力的日前预测。同时模型训练是在调度系统与配电网的交互过程中完成的，无需依赖于精确的潮流模型，可以有效应用于低感知度配电网。

本章第2节首先提出了无功优化的强化学习建模方法，明确了状态空间、动作空间、即时回报等的定义。第3节根据前文讨论的配电网潮流数据的特点，设计了一个适用于配电网无功优化问题的神经网络结构，及采用强化学习的网络训练方法。第4节以调整后的IEEE 33节点系统作为算例验证了所提电压控制方法的有效性。

### 5.2 配电网无功优化的强化学习建模方法

#### 5.2.1 无功优化的数学模型

首先回顾配电网无功优化的数学模型，考虑系统运行经济性和离散设备的调

节成本，配电网动态无功优化目标函数可以分为两个部分——网损和动作损失，目标函数定义如下：

$$\min \sum_{i=1}^N \left( P_{lossi} + \lambda_c \sum_j c_j \mathbf{1}(d_j^i) \right) \quad j=1,2,\dots,m \quad (5-1)$$

其中  $N$  为一天内的指令周期个数， $P_{lossi}$  为第  $i$  个指令周期内的系统网损， $c_j$  为第  $j$  个设备的动作成本， $\mathbf{1}(d_j^i)$  是一个 0-1 函数，第  $i$  个指令周期内第  $j$  个设备动作时为 1，否则为 0， $m$  是离散设备的数目， $\lambda_c$  是动作成本系数。约束条件定义如下

$$U^{\min} \leq U \leq U^{\max} \quad (5-2)$$

$$Q^{\min} \leq Q \leq Q^{\max} \quad (5-3)$$

$$T^{\min} \leq T \leq T^{\max} \quad (5-4)$$

$$g_i(\mathbf{X}, \mathbf{T}) = 0 \quad i=1,2,\dots,N \quad (5-5)$$

$$\sum_{i=1}^N \mathbf{1}(d_j^i) \leq A^{\max} \quad j=1,2,\dots,m \quad (5-6)$$

其中(5-2)至(5-4)分别为节点电压，无功功率和控制变量的上下限约束，(5-5)为系统潮流方程约束，(5-6)为动作次数约束（不区分 SC 和 OLTC）。

配电网的无功优化是一个典型的多步决策问题，可以用马尔科夫决策过程对其进行建模。如果将进行动作决策的调度中心作为决策主体，实际电力系统作为环境，那么配电网的无功优化模型可以转化为最优决策问题。其中约束(5-3)和(5-4)分别表示无功控制设备的容量上下限约束和档位上下限约束，可以通过定义决策主体的动作空间进行满足，约束(5-5)所示的潮流方程约束在环境（实际电力系统）运行中天然满足。式(5-2)和(5-6)所示的节点电压上下限约束和动作次数约束则和决策主体的状态与动作决策相关，需要对其进行改写，在(5-1)所示的优化目标中加入罚函数，优化目标可以改写如下

$$\min \sum_{i=1}^N \left( P_{lossi} + \lambda_c \sum_j c_j \mathbf{1}(d_j^i) \right) + \eta_1 \sigma(U^{\min} \leq U \leq U^{\max}) + \eta_2 \sigma\left(\sum_{i=1}^N \mathbf{1}(d_j^i) \leq A^{\max}\right) \quad (5-7)$$

其中  $\eta_1$  和  $\eta_2$  为很大的整数，作为惩罚系数， $\sigma$  为判断函数，约束条件满足时取值为 0，约束条件不满足时取值为 1。

### 5.2.2 配电网无功优化的马尔科夫决策过程

如前文所述，一个马尔科夫决策过程由  $\langle S, R, Pr, A, \gamma \rangle$  五个变量定义。

$S$  是状态空间，是决策主体所能够感知到环境的状态（ $s$ ）集合，在低感知配

电网无功优化问题中，可将调度中心抽象为决策主体，则状态空间为调度中心能够量测得到的电网信息，主要包括经过通信系统接入到调度中心的节点信息和离散动作设备的投切状态信息。定义第  $i$  个决策阶段的状态  $s$  如下

$$s_i \equiv \{P_i^0, Q_i^0, U_i^0, T_i, CT_i\} \quad (5-8)$$

其中  $P_i^0$ ,  $Q_i^0$ ,  $U_i^0$  分别为第  $i$  个决策阶段内调度中心可以量测得到的节点有功注入功率矩阵，无功注入功率矩阵和节点电压矩阵，维度均为  $n \times k$ ，其中  $n$  为四遥接入调度中心的节点数， $k$  为决策周期内量测次数。 $T_i$  为第  $i$  个决策阶段内离散动作设备的投切档位，采用 one hot 编码方式。 $CT_i$  为  $i$  个决策阶段内离散动作设备已经完成的动作次数，同样采用 one hot 编码方式。

举例说明，假设一个配电系统包含 20 个可观测节点，离散动作设备的决策周期为 10 min，量测设备采样周期为 1 min，则  $P_i^0$ ,  $Q_i^0$ ,  $U_i^0$  的维度为  $20 \times 10$ 。假设系统中包含两个并联电容器，档位数分别为 5 和 3，在当前决策周期下分别在 2 挡和 3 挡位置。并设设备最大的投切次数为 5，当前决策周期下，两个并联电容器已经累积投切了 3 次和 2 次，则  $T_i$  和  $CT_i$  分别表示如下

$$T_i = [0 \ 1 \ 0 \ 0 \ 0 \ 0 \ 0 \ 1] \quad (5-9)$$

$$CT_i = [0 \ 0 \ 1 \ 0 \ 0 \ 0 \ 1 \ 0 \ 0 \ 0] \quad (5-10)$$

$A$  是动作空间，是决策主体所能够对环境进行动作 ( $a$ ) 的集合，在低感知配电网无功优化问题中，可以将动作空间定义为下一指令周期下离散动作设备的档位状态，同样采用 one hot 编码

$$a_i = T_{i+1} \quad (5-11)$$

$R$  是回报空间，是环境根据状态和动作返回给决策主体的即时回报 ( $r$ ) 的集合，是评价状态与动作的指标，也是多阶段决策的优化目标，根据(5-7)的优化目标，即时回报定义如下

$$r_i = \begin{cases} -\left(P_{lossi} + \lambda_c \sum_j c_j \mathbf{1}(d_j^i)\right) & \text{if } U^{\min} \leq U_i \leq U^{\max} \text{ and } \sum_{k=1}^i \mathbf{1}(d_j^k) \leq A^{\max} \\ -\eta_1 & \text{if } U_i < U^{\min} \text{ or } U_i > U^{\max} \\ -\eta_2 & \text{if } \sum_{k=1}^i \mathbf{1}(d_j^k) > A^{\max} \end{cases} \quad (5-12)$$

即当节点电压满足约束条件且在当前指令周期下并未超过动作次数约束时，即时回报  $r_i$  为此周期内的系统网损和设备动作成本之和的相反数，当节点电压越限或者动作次数超过约束时，即时回报  $r_i$  为惩罚项的相反数，即为非常小负数。

$Pr$  是状态转移概率，由环境确定，决策主体未知。在低感知配电网无功优化问题中，环境为实际运行的配电网，在系统运行过程中，状态转移关系天然满足潮流方程约束。

$\gamma$  是回报折扣率，表示未来回报对当前决策的影响。 $\gamma$  越大，表示越关注远期的回报影响， $\gamma$  越小，表示模型更关注近期的回报影响，本文中取  $\gamma$  为固定值 0.9。

配电网无功优化对应的马尔科夫决策过程示意图如图 5.1 所示，假设在最开始的指令周期内系统处于某种初始状态  $s_0$  下，调度系统根据策略  $\pi^\theta(a|s)$  对配电网下达离散动作设备的投切指令  $a_0$ ，确定下一周期离散动作设备所处状态  $T_1$ ，其中  $\theta$  表示用于拟合控制策略的网络参数。配电网中的相关设备根据指令进行动作，更新  $CT$ ，量测设备量测系统状态，并反馈回给调度中心系统下一指令周期的状态  $s_1$ ，循环进行这一过程直至最后一个指令周期。

可以证明式(5-7)所示的优化目标与累积奖励相等，即优化目标可以改写为：

$$\min \sum_{i=1}^N r_i \quad (5-13)$$

因此模型的最优解也相当于求解这一马尔科夫过程的最优决策，即求解  $\pi^*(s)$ 。




图 5.1 配电网无功优化的马尔科夫决策过程示意图

贝尔曼最优准则是指“在一个多阶段的最优决策过程中，不论初始状态和决策如何，对于已经确定的某一状态，以其为初始状态的子过程也一定对应最优决



策”。贝尔曼最优准则是保证马尔科夫决策过程可解的理论基础。对于如图 5.1 所示的配电网无功优化马尔科夫决策过程，可以用反证法证明其满足贝尔曼最优准则。设  $s_k$  是在最优决策  $\pi^*$  下经过  $k$  步决策得到的某一状态，假设最优决策下  $\pi^*$  以  $s_k$  为初始状态的子过程对应的不是最优的，则存在某一策略  $\pi'$  使得累积回报大于在  $\pi^*$  下的累积回报，即

$$\sum_{i=k}^N r_i(s_i, \pi^*(s_i)) < \sum_{i=k}^N r_i(s_i, \pi'(s_i)) \quad (5-14)$$

由此可得

$$\sum_{i=1}^{k-1} r_i(s_i, \pi^*(s_i)) + \sum_{i=k}^N r_i(s_i, \pi^*(s_i)) < \sum_{i=1}^{k-1} r_i(s_i, \pi^*(s_i)) + \sum_{i=k}^N r_i(s_i, \pi'(s_i)) \quad (5-15)$$

与  $\pi^*$  是最优决策相悖，因此最优决策下  $\pi^*$  以  $s_k$  为初始状态的子过程对应的一定也为最优子过程，满足最优性条件，可以用强化学习相关方法在决策主体与环境的交互过程中对模型进行求解。

相比较传统动态无功优化模型，将其建模为多阶段决策的马尔科夫决策过程具有如下一些优点：

(1) 将配电网动态无功优化建模为马尔科夫决策过程无需划分为固定时段。传统配电网的动态无功优化数学模型中为了减化状态空间和动作空间，方便模型求解，通常需要把一天分为若干个时间段（如每个小时作为一个时间段），在各个时间段内假设负荷和分布式电源出力不变，并用预测值代替实际值，将动态优化问题转化为单时间断面的静态优化问题。因此求解精度与时段划分相关，时段划分越细，预测值与实际值越接近，同时问题复杂度也会相应增加。将其建模为马尔科夫过程则直接可以求解系统状态到离散动作设备投切状态的映射  $a = \pi^\theta(s)$ ，可以在系统运行过程中在每个指令周期内进行决策，更符合系统实际运行情况。

(2) 不依赖于负荷与分布式电源出力预测。马尔科夫决策过程的最优决策  $\pi^*(s)$  仅以系统当前状态的观测量作为输入，不依赖于下一决策周期的负荷预测与分布式电源出力预测。实际上，利用强化学习方法对模型进行训练是在决策主体与环境的互动过程中完成的，在此交互过程中，训练得到的决策模型可以通过价值函数隐式的学习得到对未来状态的预测。

(3) 无需精确的潮流模型。采用强化学习方法对马尔科夫决策过程进行求解是在决策主体与环境的互动过程中完成的，在此过程中，仅需环境提供下一指令周期的状态  $s_{i+1}$  和即时回报  $r_i$  即可，无需精确的潮流模型，因此可以有效应用于低感知度配电网。

### 5.3 基于深度强化学习的配电网动态无功优化

#### 5.3.1 深度神经网络结构

如前文所述，目前常用的强化学习算法主要包括三种——基于值函数的方法（Value Based Method）、基于策略的方法（Policy Based Method）和行动者-评论家方法（A2C Method）。其中行动者-评论家方法(A2C)可以有效结合基于值函数的方法和基于策略的方法，收敛性较好且数据利用率更高。因此本文采用 A2C 算法对图 5.1 所示的配电网无功优化的马尔科夫决策过程进行求解，并设计了如图 5.2 所示的深度神经网络结构拟合策略  $a = \pi^{\theta_1}(s)$  和状态价值函数  $v^{\theta_2}(s)$ ，其中  $\theta_1$  和  $\theta_2$  分别表示行动者网络（Actor Net）和评论家网络（Critic Net）的参数。




图 5.2 深度强化学习求解配电网无功优化示意图

其中行动者-评论家方法(A2C)可以有效结合基于值函数的方法和基于策略的方法，收敛性较好且数据利用率更高。因此本文采用 A2C 算法对图 5.1 所示的配电网无功优化的马尔科夫决策过程进行求解，并设计了如图 5.2 所示的深度神经网络结构拟合策略  $a = \pi^{\theta_1}(s)$  和状态价值函数  $v^{\theta_2}(s)$ ，其中  $\theta_1$  和  $\theta_2$  分别表示行动者网络（Actor Net）和评论家网络（Critic Net）的参数。

图 5.2 所示的深度神经网络结构主要包括三个部分——用于提取关键特征的卷积神经网络，拟合从状态空间到动作空间的映射的行动者网络（ $a = \pi^{\theta_1}(s)$ ），拟合状态价值函数的评论家网络（ $v^{\theta_2}(s)$ ）。

如前文所述，模型的输入为配电网无功优化的马尔科夫决策过程的状态  $s$ ，包

括可观测节点潮流矩阵  $[P^0 \ Q^0 \ U^0]_{3 \times n \times k}$ ，采用 one hot 编码的离散设备投切状态  $T$  和采用 one hot 编码的离散设备投切次数  $CT$ 。

其中节点潮流矩阵中包含了当前配电网运行过程中的所有信息，考虑到物理系统惯性，也包括了短期未来的部分信息。但是潮流矩阵维度很高，信息密度低，直接将其作为 Actor Net 和 Critic Net 的输入会导致模型参数过多而难以训练，需要首先从中提取关键信息。在节点电压的拟合任务中，深度调压网络已经表明对于电力系统潮流矩阵数据，相比较简单的全连接网络卷积神经网络结构可以更有效提取关键信息，降低模型复杂度。因此图 5.2 所示的网络结构首先用一个 3 层卷积神经网络作为 Conv Body 提取关键特征，如图中虚线方框所示。

然后将 Conv Body 得到的关键特征（用  $f_{conv}$  表示）和投切状态矩阵  $T$  及投切次数矩阵  $CT$  进行拼接得到 Actor Net 和 Critic Net 的输入。Actor Net 是一个三层全连接网络结构，输入维度为潮流特征矩阵  $f_{conv}$ 、投切状态矩阵  $T$  和投切次数矩阵  $CT$  的维度之和，即  $\mathcal{D}(f_{conv}) + \mathcal{D}(T) + \mathcal{D}(CT)$ ，两个隐含层分别有 200 个神经元和 100 个神经元，输出维度为投切状态矩阵  $T$  的维度，即  $\mathcal{D}(T)$ ，输出经过 softmax 层，转化为  $m$  个多项式分布概率，其中  $m$  为系统中离散动作设备的数目。

Critic Net 与 Actor Net 输入相同，同样为潮流特征矩阵  $f_{conv}$ 、投切状态矩阵  $T$  和投切次数矩阵  $CT$  拼接得到的状态矩阵。Critic Net 也同样为三层全连接网络，两个隐含层分别有 200 个神经元和 100 个神经元。与 Actor Net 不同的是 Critic Net 拟合的是状态价值函数  $v^{\theta_2}(s)$ ，输出维度为 1，且不需要经过 softmax 层。

### 5.3.2 神经网络优化算法

图 5.2 所示的深度神经网络需要在和环境的互动过程中进行训练。其中的 Actor Net 没有明确的动作标签，需要在和环境的交互过程中采用策略梯度法 (PG) 进行优化，如前文所述，常用的策略梯度法的优化目标为：

$$J^1(\theta_1) = E_t \left( -\log(\pi^{\theta_1}(a|s)) A_t(s, a) \right) \quad (5-16)$$

其中  $s$  和  $a$  分别表示无功优化的马尔科夫决策过程的状态和动作，由式(5-8)和(5-11)定义， $\pi^{\theta_1}(a|s)$  为用深度神经网络拟合的策略， $\theta_1$  表示 Actor Net 的参数， $A_t$  表示动作优势函数，由式(2-19)定义， $E_t$  表示经过在无数次交互过程中进行采样的期望。优化目标函数对模型参数的梯度可以用下式表示：

$$\nabla J^1(\theta_1) = E_t \left( -\nabla \log(\pi^{\theta_1}(a|s)) A_t(s, a) \right) \quad (5-17)$$

可以对其中的动作优势函数进行改写为如下形式：

$$\begin{aligned} A_t(s, a) &= q(s, a) - v^{\theta_2}(s) \\ &= r(s, a) + \gamma v^{\theta_2}(s') - v^{\theta_2}(s) \end{aligned} \quad (5-18)$$

其中  $v^{\theta_2}(s)$  表示状态  $s$  的状态价值函数， $\theta_2$  表示 Critic Net 的参数， $q(s, a)$  表示状态  $s$  下动作  $a$  的动作价值函数，分别由(2-17)和(2-18)定义， $r(s, a)$  在状态  $s$  下采取动作  $a$  的即时回报，由式(5-12)定义， $s'$  表示在状态  $s$  下采取动作  $a$  的后继状态， $\gamma$  表示折扣系数。

Critic Net 的作用是拟合价值状态函数，其标签可以根据贝尔曼方程，用蒙特卡洛法或者时间差分法得到，本文选用时间差分法计算 Critic Net 的标签，因此 Critic Net 的优化目标可以用下式表示：

$$J^2(\theta_2) = \left( r(s, a) + \gamma v^{\theta_2}(s') - v^{\theta_2}(s) \right)^2 \quad (5-19)$$

假设在一个决策主体与环境的交互过程中，收集到了  $N$  个有效的互动过程  $\{(s_i, a_i, r_i, s'_i)\}_N$ ，那么模型训练的损失函数可以由下式定义：

$$J(\theta) = J(\theta_1) + \lambda J(\theta_2) \quad (5-20)$$

$$J(\theta) = \sum_{i=1}^N \left( -A(s_i, a_i) \log(\pi^{\theta_1}(a_i | s_i)) + \lambda \left( r(s_i, a_i) + \gamma v^{\theta_2}(s'_i) - v^{\theta_2}(s_i) \right)^2 \right) \quad (5-21)$$

其中  $\lambda$  为权重系数。目前常用的深度学习框架如 pytorch, tensorflow 等支持自动微分功能，因此可以直接计算  $\nabla \log(\pi^{\theta_1}(a | s))$ ，从而实现模型的训练。

## 5.4 算例分析

### 5.4.1 算例系统介绍




图 5.3 加入分布式电源和并联电容器的算例系统

为了验证本章所提配电网无功优化的强化学习建模方法的有效性，在图 3.5

经过调整的 IEEE 33 节点系统中的 8 号、18 号和 32 号节点上加入 3 个并联电容器，容量分别为 2MW，1MW，1MW。同时为了使得并联电容器的无功调节对系统作用更加明显，也对系统联络线参数做了一定调整，并减小了其中的分布式电源容量为每个 0.75MW。其中两个典型日系统的有功无功总负荷和分布式电源总出力如图 5.4 所示。

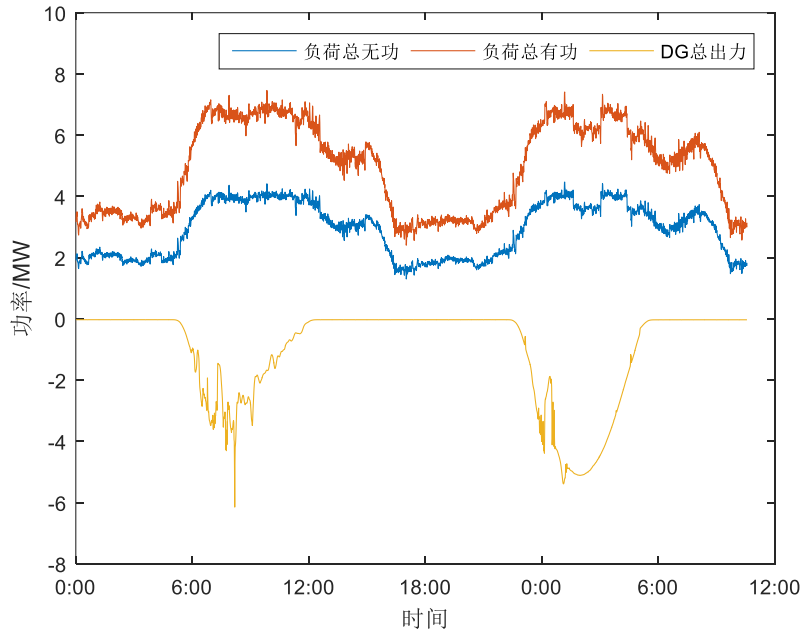


图 5.4 系统总负荷与分布式电源总出力

#### 5.4.2 深度强化学习训练过程

采用强化学习方法对无功优化问题求解是在决策主体与环境的交互过程中完成的。因此在仿真过程中，还需要搭建代替实际配电网的训练环境。在 matlab 中通过潮流计算模拟实际配电网的运行过程代替强化学习训练环境，用 python 进行深度神经网络的训练，交互过程可以依赖于二者之间的接口实现。训练环境的主要步骤包括如下：

环境初始化并加载负荷和分布式电源出力数据，然后从模拟调度系统的行动者评论家网络中获得当前指令周期的系统动作指令，并根据动作指令经过潮流计算完成相应动作。然后根据系统状态计算即时奖励，并将新的指令周期内的状态变量  $s'$  和即时奖励  $r$  反馈给决策主体。决策主体接收到状态变量  $s'$  和即时奖励  $r$  后根据式(5-21)进行深度神经网络的训练，并作出相应决策  $a' = \pi^\theta(s')$ ，反馈给训练环境。此过程反复进行直到深度神经网络收敛。

设(5-12)中的动作成本系数  $\lambda_c$  为 1，设备动作的成本均为 3，电压越限和设备

动作次数越限的罚函数系数均为 100。设离散无功调节设备的指令周期为 20 分钟，以一天作为一个回合，即当发生电压越限、动作次数越限或一天结束后，回合结束。对于图 5.2 所示的神经网络采用本文提出的深度强化学习算法以式(5-21)所示的损失函数进行模型训练，训练总共进行约 1000 回合，训练过程中的损失函数变化如图 5.5 所示。其中的蓝线和红线分别为累积回报的实际值与平滑后的回报曲线。从中可以看出，在训练的前 100 个回合内，几乎一直处于动作次数越限的状态，因此累积回报始终在-100 附近。之后动作次数开始逐渐减少，满足动作次数约束，累积回报也开始逐步上升，经过约 500 个回合，累积回报收敛到-50 附近，达到比较好的控制策略。同时也可以发现，图中蓝色曲线显示每个回合的累积回报波动范围很大，这是由于神经网络在探索不同的控制策略，神经网络的训练也是在逐步的试错过程中完成训练的。




图 5.5 深度强化学习训练过程

### 5.4.3 仿真结果

#### 5.4.3.1 不同无功补偿容量下的系统网损

对于图 5.3 和图 5.4 所示的算例系统，在不加入任何无功补偿、加入 2MVar 无功补偿和加入 4MVar 无功补偿（3 个电容器按照容量分配）的系统网损如图 5.6 所示。在不加入任何无功补偿时，某两个典型日系统总的网损为 19.263MWh，从图中可以看出，由于分布式电源的无功出力难以补偿系统所有的无功负荷，需要从主网吸收大量的无功，造成有功损失，因此系统网损一直处于较高的水平。

在系统中加入 2MVar 和 4MVar 的并联电容器无功补偿之后,系统网损分别为 11.79MWh 和 12.57MWh,相比无无功补偿时系统网损分别下降 38.79%和 34.74%,可以显著降低网损。因此在配电网中加入并联电容器可以有效提升系统运行经济性。同时可以发现,在系统有功和无功负荷较小时,此时系统网损处于较低水平,加入 2MVar 的并联电容器的系统网损比加入 4MVar 的并联电容器的系统网损更小(黄色曲线始终在红色曲线下方)。在系统有功和无功负荷较大时,系统网损处于较高水平,此时加入 4MVar 的并联电容器的系统网损更小。因此考虑系统的负荷与分布式电源出力波动,对系统中的离散动作设备进行相应的无功优化对进一步降低系统网损,提高系统经济性具有重要意义。




图 5.6 不同电容器补偿条件下的系统网损

#### 5.4.3.2 深度强化学习得到的动作决策

设置图 5.3 所示的算例系统中的 1 号电容器(SC1)总共有 6 档,每档 0.4MVar, 2 号和 3 号电容器(SC2 和 SC3)均有 3 挡,每档 0.5Mar,并设每个电容器每天动作次数上限为 5 次,并假设电容器的决策周期为 20 min,即每 20 分钟下发一次电容器投切指令。采用深度强化学习优化得到的电容器动作决策如图 5.7 所示。从图中可以看出,第一天三个电容器分布动作了 2 次,0 次和 2 次;第二天三个电容器分别动作了 3 次,0 次和 2 次,满足动作次数约束。系统中固定补偿 4MVar、系统中固定补偿 2MVar 和采用深度强化学习进行无功优化的系统网损如图 5.8 所示。

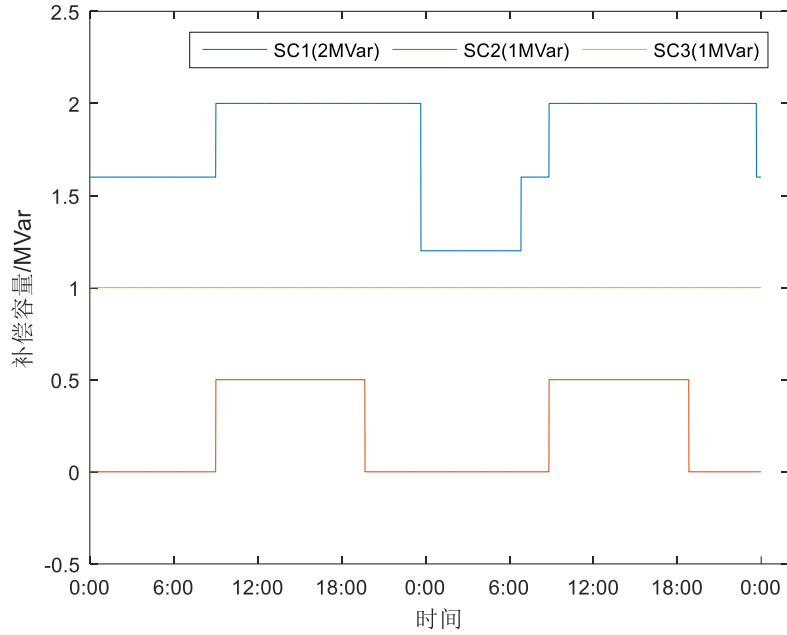


图 5.7 深度强化学习优化后的电容器动作

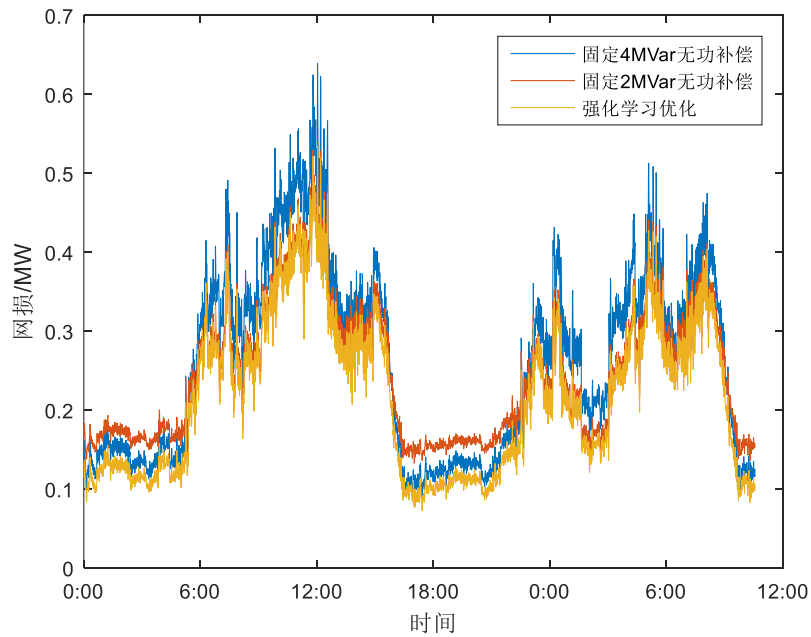


图 5.8 深度强化学习优化后的系统网损

经过深度强化学习优化得到的系统网损为 10.43 MWh，相比固定电容补偿 4MVar 和 2MVar 情况下的系统网损分别降低了 17.02% 和 11.53%。从图中也可以看出，经过深度强化学习进行无功优化的系统网损曲线一直在固定容量补偿的网损



曲线下方，说明了经过强化学习的动态无功优化，系统运行经济性得到了一定的提升。

经过强化学习进行无功优化后，系统的总负荷和分布式电源总出力如图 5.9 所示，为了加速模型训练过程，DG 采用 QV 下垂控制参与无功调节，并且为了突出并联电容器的调节作用，设 DG 的功率因数需大于 0.95，以限制 DG 的无功调节容量。在图 5.9 中，我们把并联电容器和 DG 的容性无功功率作为负无功负荷，因此图中的系统总无功即为从高压网吸收的无功功率。从图中可以看出，经过无功优化后，从高压网吸收的无功功率始终处于较低水平，在 0MVar 附近，可以有效减少变压器上的有功损失，提高系统运行经济性。




图 5.9 深度强化学习优化后的系统注入功率

#### 5.4.3.3 与传统无功优化算法的对比

如前文所示，传统的无功优化算法主要包括状态空间与动作空间简化法、负荷分段法、动作成本法等。其中负荷分段法将负荷和分布式电源分成与动作次数约束相对应的固定的几段，并假设每个时间段内功率不发生变化，用预测的均值进行代替。尽管在时间段内无功调节设备可以动作，从而满足调节次数的约束，并实现了调节次数在时间上的解耦，实现较为简单，是目前较为常用的一种方式，接下来将这种优化方法与经过深度强化学习的无功优化结果进行对比。

同样假设一天并联电容器的调节次数上限为 5 次，因此需要将一天分为 5 个时间段，每个时间段内的并联电容器投切情况如图 5.10 所示。从图中可以看出，在第一天，三个电容器分别动作了 3 次，0 次和 3 次。第二天，三个电容器分别动

作了 2 次, 0 次和 2 次。均满足系统的 5 次动作次数约束, 并且并联电容器的动作均发生在时间段之间。在传统无功优化算法下, 系统网损为 10.74MWh, 动作次数与经过强化学习优化得到的投切策略相当, 但是网损更大。




图 5.10 传统无功优化算法得到的并联电容动作指令

在传统无功优化算法得到的电容投切策略下, 系统的负荷和分布式电源出力如图 5.11 所示。




图 5.11 传统无功优化算法的系统总负荷与 DG 总出力

从图中可以看出，相比较进行无功优化之前，系统从高压电网吸收的无功功率也处于较低水平，在 0MVar 附近。但是由于无功调节设备的动作时间受限，无法及时响应系统的负荷与分布式电源出力波动，因此并未达到全局优化，系统网损更大。从图 5.11 中也可以发现，电容器进行投切调节时，无功总负荷存在一个较大的跳变，说明在设备动作之前，系统运行状态已经远离了最优点，导致系统运行经济性偏低。

#### 5.4.3.4 动作成本系数的影响




图 5.12 较低设备动作成本下的深度强化学习优化结果

改变模型(4-12)中的动作成本系数  $\lambda_c$ ，将其降低为 0.1，即系统更加偏向于用更多的调节次数得到更小的系统网损，同样设置每天的每个电容器每天最大的调节次数为 5 次。用本文所提的深度强化学习方法进行训练得到的电容投切策略如图 5.12 所示。从图中可以看出，第一天，三个电容器分别动作了 4 次，0 次和 2 次。第二天，三个电容器分别动作了 5 次，0 次和 4 次。两天时间内，系统总的网损为 10.39MWh。相比原始的深度强化学习得到的结果电容器动作次数更多，但是系统网损更小，与预期相符。

#### 5.4.3.5 总结

总结以上仿真结果，在图 5.3 所示的算例系统中，随机选择 30 天的负荷和光伏出力分别在不采用任何无功补偿装置、采用固定的无功补偿（三个电容的无功

容量分别为 2、1、1)、采用分段的传统无功优化算法、采用深度强化学习优化算法几种无功策略下进行实验。除系统的平均网损外,选择电容器的平均动作次数和平均动作里程作为评价指标,对几种无功策略进行评价,平均动作里程定义如下:

$$MV = \frac{\sum_{i=2}^N \sum_{j=1}^3 |T_i^j - T_{i-1}^j|}{K} \quad (5-22)$$

其中  $MV$  表示平均动作里程,  $K$  表示天数,取值为 30,  $N$  为 30 天内的指令周期数目,  $T_i^j$  表示在第  $i$  个指令周期下,第  $j$  个电容器的投切档位。平均动作里程可以有效评价电容器是否反复投切。

表 5.1 不同无功策略下的评价指标

	平均动作 次数	平均动作 里程	平均网损 MWh
不加入电容器补偿	0	0	9.6315
加入固定的补偿([2 1 1])	0	0	6.285
传统无功优化算法	4.933	3.2	5.530
强化学习优化	4.667	2.467	5.416

在以上所述的不同无功策略下的评价指标如表 5.1 所示,从表中可以看出,通过加入合适的无功补偿策略,可以有效减小系统网损,提高系统运行经济性,说明了进行无功优化的必要性。与采用固定的无功补偿和采用传统分段求解的无功优化算法相比,本文提出的基于强化学习的无功优化算法平均网损分别下降 13.82%和 2.16%。与传统无功优化算法相比,本文提出的基于强化学习的无功优化算法的平均动作次数和平均动作里程分别下降 5.39%和 22.9%,可以看出虽然动作次数相差不大,但是动作里程有明显减小,说明采用强化学习算法优化后的设备投切策略可以更有效的提高设备动作的合理性,减少额外投切。同时,通过调小动作成本系数,可进一步降低系统成本,但同时无功调节设备的动作次数和动作里程会相应增加。

## 5.5 本章小结

本章以深度强化学习为基础提出了适用于低感知度配电网的无模型无功优化方法。提出了配电网无功优化的强化学习建模方法,将无功优化建模为马尔科夫决策过程,以系统观测的潮流矩阵、节点电压、离散调节设备的投切状态和动作

次数作为状态空间，以离散调节设备的投切状态作为动作空间，以系统网损和动作成本之和作为即时回报。配电网的动态无功优化可以转化为最大化累积回报的多阶段决策问题。然后针对配电网潮流数据的特点，设计了一个适用于配电网无功优化问题的 Actor Critic 神经网络结构直接拟合系统状态到设备投切策略之间的函数关系，该神经网络首先用一个卷积神经网络结构提取潮流矩阵和节点电压矩阵中的关键特征映射，然后将关键特征映射、离散调节设备的投切状态向量和投切次数向量拼接作为状态向量。Actor Net 和 Critic Net 以状态向量作为输入，以离散设备投切指令和动作优势函数作为输出，直接拟合得到投切策略。

系统状态和即时回报均只依赖于系统的观测量，并且模型的训练是在和实际系统的交互过程中，用深度强化学习算法完成的，无需精确的潮流模型，可以实现无模型的无功优化。训练好的神经网络可以在系统中实现实时决策，无需依赖于负荷和分布式电源出力的日前预测，且无需分段求解。相比较传统分段法的动态无功优化算法，在调整后的 IEEE 33 节点算例系统中，采用强化学习算法优化后平均网损、平均设备动作次数和平均里程分别下降 2.16%、11.39% 和 22.9%。

## 第6章 结论

DG 的大规模接入给配电网电压控制与无功优化带来了新的挑战。本文致力于解决在建模精度与通信系统约束条件下, 合理利用多类型无功调节资源, 实现对低感知配电网的电压控制与无功优化问题, 以提高系统运行的稳定性与经济性。论文采用数据驱动的方法解决配电网的低感知度问题, 从调压函数拟合、连续无功调节设备的电压控制和离散无功调节设备的无功优化几个方面开展研究, 主要研究成果如下:

**(1) 针对我国配电网的低观测覆盖率与低建模精度的现状, 提出了深度调压网络直接拟合节点注入功率与节点电压之间的函数关系, 用数据驱动的方法解决了配电网的低感知度问题。**

本文针对我国当前分布式电源接入的配电网现状, 明确了低感知度配电网的概念与电压控制中应满足的系统条件。对于低感知度配电网, 节点注入功率与节点电压之间的调压函数关系难以由潮流方程直接获得, 本文采用一个深度神经网络在历史运行数据上直接拟合这一函数关系。并基于潮流矩阵与调压函数的数据结构与任务特点设计了深度调压网络, 提高了模型的拟合精度和拟合效率。讨论了训练数据量、网络结构与系统感知度对拟合精度的影响。深度调压网络以可观测节点注入潮流矩阵作为模型输入, 以关键节点电压作为模型输出, 优化后的深度调压网络可以代替由潮流方程确定的调压函数关系, 无需依赖于电气参数的计算, 是配电网电压控制与无功优化的基础, 用数据驱动的方式解决了配电网的低感知度问题。

**(2) 针对潮流分布改变引起的配电网沿线电压分布差异大的问题, 提出了基于深度调压网络的无潮流模型依赖的电压控制方法。利用系统中连续无功调节设备的无功调节能力, 提高了系统的电压水平。**

低感知度配电网的调度系统中没有精确的网络结构与电气参数, 传统电压控制方法中的无功电压灵敏度难以直接获得。针对这一问题, 本文以深度调压网络为基础提出了适用于低感知度配电网的集中式电压控制方法。所提方法选择分布式电源并网点与电网末端节点作为关键节点, 以关键节点电压与参考值的偏差作为优化目标, 可观测分布式电源出力作为控制变量, 通过控制关键节点电压实现对全网电压的控制。针对配电网的低感知度状态, 用在历史运行数据上预训练好的深度调压网络代替无功电压灵敏度, 提出了基于梯度下降法的模型求解方法。控制梯度可以直接通过梯度回传得到, 无需依赖系统的潮流模型, 可以有效应用

于低感知度配电网实现无模型的集中式电压控制。算例分析显示，本文所提电压控制方法可以使节点电压分布在参考值附近，可以有效降低系统的过电压风险。

**(3) 针对分布式电源导致的配电网系统状态波动问题，提出了基于深度强化学习的多时间断面的连续无功优化方法。利用配电网中的离散无功调节设备提高了系统运行经济性。**

分布式电源出力的强波动性使得配电网的无功优化问题难以分段求解，针对这一问题，本文提出了一种基于深度强化学习的多时间断面下的连续无功优化模型。该模型将传统配电网的无功优化问题转化为一个马尔科夫决策过程。用一个深度神经网络直接拟合系统状态到离散无功调节设备的投切动作的函数关系，并针对潮流矩阵的数据特点优化了深度神经网络的结构。在与实际配电网的交互过程中采用强化学习算法完成网络训练。相比传统无功优化方法，该模型无需进行分段，且不依赖于日前的负荷与分布式电源出力预测，可以实现实时的多时间断面下的连续无功优化。算例分析显示，本文所提连续优化方法可以在满足动作次数约束条件下，有效减少系统网损，提高系统运行经济性。

## 参考文献

- [1] 国家能源局. 2018 年光伏发电统计信息 [EB/OL]. (2019-03-19) [2019-04-10]. [http://www.nea.gov.cn/2019-03/19/c\\_137907428.htm](http://www.nea.gov.cn/2019-03/19/c_137907428.htm)
- [2] 国家能源局. 2018 年风电并网运行情况 [EB/OL]. (2019-01-28) [2019-04-10]. [http://www.nea.gov.cn/2019-01/28/c\\_137780779.htm](http://www.nea.gov.cn/2019-01/28/c_137780779.htm)
- [3] 王志群, 朱守真, 周双喜, 等. 分布式发电对配电网电压分布的影响. 电力系统自动化, 2004, 28(16): 56-60
- [4] 王颖, 文福拴, 赵波, 等. 高密度分布式光伏接入下电压越限问题的分析与对策. 中国电机工程学报, 2016, 36(5): 1200-1206
- [5] Thomson M, Infield D G. Impact of widespread photovoltaics generation on distribution systems. Renewable Power Generation Iet, 2007, 1(1): 33-40
- [6] 许晓艳, 黄越辉, 刘纯, 等. 分布式光伏发电对配电网电压的影响及电压越限的解决方案. 电网技术, 2010, 34(10): 140-146
- [7] Christakou K, Paolone M, Abur A. Voltage Control in Active Distribution Networks Under Uncertainty in the System Model: A Robust Optimization Approach. IEEE Transactions on Smart Grid, 2017, 9(6): 5631-5643
- [8] Lecun Y, Bengio Y, Hinton G. Deep learning. Nature, 2015, 521(7553): 436-445
- [9] 付英杰, 汪汛, 陈春, et al. 考虑分布式电源的配电网电压控制新方法. 电力系统及其自动化学报, 2015, 27(6):26-31.
- [10] 蔡凯. 电压无功综合控制装置控制原理的新讨论——由“九区图”到“五区图”. 电力系统自动化, 2004, 28(19):92-95.
- [11] 吴慧政, 赵景水, 王峰, et al. 基于九区图法的变电站VQC频繁动作的分析和预防. 电力学报, 2007(1):65-67.
- [12] 侯雪. 基于多区图的变电站电压无功综合调控策略研究[硕士学位论文]. 北京: 华北电力大学, 2013.
- [13] Short T A , Grigsby L L . Electric Power Distribution Handbook. Omega, 2005, 15(1):79-82.
- [14] Antoniadou-Plytaria K E, Kouveliotis-Lysikatos I N, Georgilakis P S, et al. Distributed and Decentralized Voltage Control of Smart Distribution Networks: Models, Methods, and Future Research. IEEE Transactions on Smart Grid, 2017, 8(6): 2999-3008
- [15] Mahmud N, Zahedi A. Review of control strategies for voltage regulation of the smart distribution network with high penetration of renewable distributed generation. Renewable & Sustainable Energy Reviews, 2016, 64: 582-595
- [16] 蔡永翔, 唐巍, 徐鸥洋, 等. 含高比例户用光伏的低压配电网电压控制研究综述. 电网技术, 2018, 42(1): 220-229
- [17] Jahangiri P, Aliprantis D C. Distributed Volt/VAr Control by PV Inverters. IEEE Transactions on Power Systems, 2013, 28(3): 3429-3439



- 
- [18] Samadi A, Eriksson R, Soder L, et al. Coordinated Active Power-Dependent Voltage Regulation in Distribution Grids With PV Systems. *IEEE Transactions on Power Delivery*, 2014, 29(3): 1454-1464
  - [19] Pham H V, Erlich I, Rueda J L. Probabilistic evaluation of voltage and reactive power control methods of wind generators in distribution networks. *Renewable Power Generation Iet*, 2014, 9(3): 195-206
  - [20] Demirok E, González P C, Frederiksen K H B, et al. Local Reactive Power Control Methods for Overvoltage Prevention of Distributed Solar Inverters in Low-Voltage Grids. *IEEE Journal of Photovoltaics*, 2011, 1(2): 174-182
  - [21] Vasquez J C, Mastromauro R A, Guerrero J M, et al. Voltage Support Provided by a Droop-Controlled Multifunctional Inverter. *IEEE Transactions on Industrial Electronics*, 2009, 56(11): 4510-4519
  - [22] Alam M J E, Muttaqi K M, Sutanto D. A Multi-Mode Control Strategy for VAr Support by Solar PV Inverters in Distribution Networks. *IEEE Transactions on Power Systems*, 2015, 30(3): 1316-1326
  - [23] 魏昊焜, 刘健. 可消除无功振荡的分布式电源本地电压控制策略. *高电压技术*, 2018, 44(7): 2354-2361
  - [24] Cavraro G, Carli R. Local and distributed voltage control algorithms in distribution network. *IEEE Transactions on Power Systems*, 2017, 33(2): 1420-1430
  - [25] Liu H J, Shi W, Zhu H. Distributed Voltage Control in Distribution Networks: Online and Robust Implementations. *IEEE Transactions on Smart Grid*, 2018, 9(6): 6106-6117
  - [26] 王笑雪, 徐弢, 王成山, 等. 基于MAS的主动配电网分布式电压控制. *中国电机工程学报*, 2016, 36(11): 2918-2926
  - [27] Nedic A, Ozdaglar A. Distributed Subgradient Methods for Multi-Agent Optimization. *IEEE Transactions on Automatic Control*, 2009, 54(1): 48-61
  - [28] Xu Y, Zhang W, Liu W, et al. Distributed Subgradient-Based Coordination of Multiple Renewable Generators in a Microgrid. *IEEE Transactions on Power Systems*, 2013, 29(1): 23-33
  - [29] Maknouninejad A, Qu Z. Realizing Unified Microgrid Voltage Profile and Loss Minimization: A Cooperative Distributed Optimization and Control Approach. *IEEE Transactions on Smart Grid*, 2014, 5(4): 1621-1630
  - [30] Cagnano A, Tuglie E D. Centralized voltage control for distribution networks with embedded PV systems. *Renewable Energy*, 2015, 76: 173-185
  - [31] Tsuji T, Tomura K, Oyama T, et al. A Study of Centralized Voltage Profile Control of Distribution Network considering Dynamics of Distributed Generator. *Electrical Engineering in Japan*, 2012, 179(1): 29-39
  - [32] Kulmala A, Repo S, Jarventausta P. Coordinated Voltage Control in Distribution Networks Including Several Distributed Energy Resources. *IEEE Transactions on Smart Grid*, 2014, 5(4): 2010-2020

- [33] Molina-García Á, Mastromauro R A, García-Sánchez T, et al. Reactive Power Flow Control for PV Inverters Voltage Support in LV Distribution Networks. *IEEE Transactions on Smart Grid*, 2017, 8(1): 447-456
- [34] 蔡永翔, 唐巍, 张璐, 等. 基于光伏逆变器无功调节的低压配电网多模式电压控制. *电力系统自动化*, 2017, 41(13): 133-141
- [35] Bidgoli H S, Cutsem T H V. Combined Local and Centralized Voltage Control in Active Distribution Networks. *IEEE Transactions on Power Systems*, 2018, 33(2): 1374-1384
- [36] 李鹏, 于航, 夏曼, 等. 分布式光伏集群分层多模式无功控制策略. *电网技术*, 2016, 40(10): 3038-3044
- [37] Kryonidis G, Kontis E, Chrysochos A, et al. A Coordinated Droop Control Strategy for Overvoltage Mitigation in Active Distribution Networks. *IEEE Transactions on Smart Grid*, 2018, 9(5): 5260-5271
- [38] Mokhtari G, Ghosh A, Nourbakhsh G, et al. Smart Robust Resources Control in LV Network to Deal With Voltage Rise Issue. *IEEE Transactions on Sustainable Energy*, 2013, 4(4): 1043-1050
- [39] Vovos P N, Kiprakis A E, Wallace A R, et al. Centralized and Distributed Voltage Control: Impact on Distributed Generation Penetration. *IEEE Trans Power Syst*, 2007, 22(1): 476-483
- [40] 郭康. 含光伏电站配电网无功优化的研究[硕士学位论文]. 北京: 华北电力大学, 2012
- [41] 蔡昌春. 电力系统动态无功优化方法研究及其实现[硕士学位论文]. 南京: 河海大学, 2007
- [42] 胡泽春, 王锡凡. 配电网无功优化的分时段控制策略. *电力系统自动化*, 2002, 26(6): 45-49
- [43] 任晓娟, 邓佑满, 赵长城, 等. 高中压配电网动态无功优化算法的研究. *中国电机工程学报*, 2003, (01): 32-37
- [44] 刘明波, 朱春明, 钱康龄, 等. 计及控制设备动作次数约束的动态无功优化算法. *中国电机工程学报*, 2004, (03): 39-45
- [45] 张勇军, 任震. 电力系统动态无功优化调度的调节代价. *电力系统自动化*, 2005, (02): 34-38
- [46] 张勇军, 俞悦, 任震, 等. 实时环境下动态无功优化建模研究. *电网技术*, 2004, 28(12): 12-15
- [47] 蔡昌春, 丁晓群, 王宽, 等. 动态无功优化的简化方法及实现. *电力系统自动化*, 2008, 32(5): 43-46
- [48] 孙田, 邹鹏, 杨知方, 等. 动态无功优化的多阶段求解方法. *电网技术*, 2016, 40(6): 1804-1810
- [49] 覃海, 姬源, 周川梅, 等. 计及控制设备动作次数约束的三阶段动态无功优化算法. *电力自动化设备*, 2018, 38(09): 179-186
- [50] 季玉琦, 耿光飞, 温渤婴, 等. 基于最优分割法的含DG配电网动态无功优化. *电网技术*, 2017, 41(08): 2585-2593
- [51] 赖晓文, 马晓伟, 白杨, 等. 基于混合整数二阶锥规划的动态无功优化方法. *电力系统自动化*, 2017, 41(17): 37-42

- [52] 周任军, 段献忠, 周晖. 计及调控成本和次数的配电网无功优化策略. 中国电机工程学报, 2005, 25(9): 23-28
- [53] 肖军, 刘天琪, 苏鹏. 基于双种群粒子群算法的分时段电力系统无功优化. 电网技术, 2009, 33(08): 72-77
- [54] 李芝荣. 基于差分退火算法的电力系统动态无功优化研究[硕士学位论文]. 南宁: 广西大学, 2013
- [55] Girshick R, Donahue J, Darrell T, et al. Rich feature hierarchies for accurate object detection and semantic segmentation, 2014, 580-587
- [56] Bahdanau D, Cho K, Bengio Y. Neural machine translation by jointly learning to align and translate[OL]. arXiv: preprint arXiv, 2014[2019-04-17]. <https://arxiv.org/abs/1409.0473v2>
- [57] Cho K, Van Merri E Nboer B, Gulcehre C, et al. Learning phrase representations using RNN encoder-decoder for statistical machine translation[OL]. arXiv: preprint arXiv, 2014. [2019-04-17] <https://arxiv.org/abs/1406.1078>
- [58] Graves A, Mohamed A, Hinton G. Speech recognition with deep recurrent neural networks: IEEE, 2013, 6645-6649
- [59] Graves A, Jaitly N. Towards end-to-end speech recognition with recurrent neural networks, 2014, 1764-1772
- [60] Graves A. Generating sequences with recurrent neural networks[OL]. arXiv: preprint arXiv, 2013 [2019-04-17]. <https://arxiv.org/abs/1308.0850>
- [61] Hinton G E, Salakhutdinov R R. Reducing the dimensionality of data with neural networks. science, 2006, 313(5786): 504-507
- [62] Hinton G E, Osindero S, Teh Y. A fast learning algorithm for deep belief nets. Neural computation, 2006, 18(7): 1527-1554
- [63] Lecun Y, Boser B, Denker J S, et al. Backpropagation applied to handwritten zip code recognition. Neural computation, 1989, 1(4): 541-551
- [64] Sutskever I, Hinton G E, Krizhevsky A. Imagenet classification with deep convolutional neural networks. Advances in neural information processing systems, 2012: 1097-1105
- [65] Simonyan K , Zisserman A. Very Deep Convolutional Networks for Large-Scale Image Recognition[C]. Computer Vision and Pattern Recognition, 2014:1-14.
- [66] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition, 2016, 770-778
- [67] Huang G, Liu Z, Van Der Maaten L, et al. Densely connected convolutional networks, 2017, 4700-4708
- [68] Ren S, He K, Girshick R, et al. Faster R-CNN: towards real-time object detection with region proposal networks, 2015, 91-99
- [69] Long J, Shelhamer E, Darrell T. Fully convolutional networks for semantic segmentation, 2015, 3431-3440
- [70] Chen K, Hu J, He J. Detection and Classification of Transmission Line Faults Based on Unsupervised Feature Learning and Convolutional Sparse Autoencoder. IEEE Transactions on

- Smart Grid, 2018, 9(2): 594-604
- [71] Chen K, Chen K, Wang Q, et al. Short-term Load Forecasting with Deep Residual Networks. IEEE Transactions on Smart Grid, 2018, DOI: 10.1109/TSG.2018.2844307..
- [72] 胡伟, 郑乐, 闵勇, 等. 基于深度学习的电力系统故障后暂态稳定评估研究. 电网技术, 2017, (10): 3140-3146
- [73] Bellman R. On the theory of dynamic programming. Proceedings of the National Academy of Sciences of the United States of America, 1952, 38(8): 716-720
- [74] Sutton R S. Learning to predict by the methods of temporal differences. Machine learning, 1988, 3(1): 9-44
- [75] Kröse B J A. Learning from delayed rewards. Robotics and Autonomous Systems, 1995, 15(4):233-235.
- [76] Sutton R S, Barto A G. Reinforcement learning: An introduction. MIT press, 2018
- [77] Mnih V, Kavukcuoglu K, Silver D, et al. Human-level control through deep reinforcement learning. Nature, 2015, 518(7540): 529-533
- [78] Silver D, Huang A, Maddison C J, et al. Mastering the game of Go with deep neural networks and tree search. Nature, 2016, 529(7587): 484-489
- [79] Van Hasselt H, Guez A, Silver D. Deep reinforcement learning with double q-learning[C]. Association for the Advance of Artificial Intelligence Conference, 2016:1-13
- [80] Wang Z, Schaul T, Hessel M, et al. Dueling network architectures for deep reinforcement learning[OL]. arXiv: preprint arXiv, 2015 [2019-04-17]. <https://arxiv.org/abs/1511.06581>
- [81] Schulman J, Wolski F, Dhariwal P, et al. Proximal policy optimization algorithms[OL]. arXiv: preprint arXiv, 2017 [2019-04-17]. <https://arxiv.org/abs/1707.06347v1>
- [82] Mnih V, Badia A P, Mirza M, et al. Asynchronous methods for deep reinforcement learning, 2016, 1928-1937
- [83] Silver D , Lever G , Heess N , et al. Deterministic policy gradient algorithms[C]. International Conference on International Conference on Machine Learning, 2014:1-8
- [84] Lillicrap T P, Hunt J J, Pritzel A, et al. Continuous control with deep reinforcement learning[OL]. arXiv: preprint arXiv, 2015 [2019-04-17]. <https://arxiv.org/abs/1509.02971>
- [85] 陈星莺, 钱锋, 杨素琴. 模糊动态规划法在配电网无功优化控制中的应用. 电网技术, 2003, (02): 68-71
- [86] Hsu Y Y, Kuo H C. Dispatch of capacitors on distribution system using dynamic programming. Generation Transmission & Distribution Iee Proceedings C, 2002, 140(6): 433-438
- [87] Lu F C, Hsu Y Y. Fuzzy Dynamic Programming Approach To Reactive Power/Voltage Control In A Distribution Substation. IEEE Transactions on Power Systems, 1997, 12(2): 681-688

## 致 谢

转眼间在清华园的六年时光已经走向尾声，在园子里的这段时光将是我人生中最宝贵的财富。

首先衷心感谢导师乔颖老师孜孜不倦的教诲。乔颖老师在我迷茫时为我指明了前进的方向，论文是在和乔老师一遍遍的讨论中完成的，乔老师严谨务实的科研态度、深厚的学术积累与广博的见识眼界让我获益良多

实验室的鲁宗相副教授在研究过程中给予了大量指导，对我开阔研究思路、寻找研究突破口、修改论文过程中给予了许多帮助，在此表示衷心感谢。

感谢周双喜教授及课题组其他老师对论文修改提出的宝贵建议。

感谢课题组叶一达、李昊、姜继恒、黎上强、林弋莎等同学在硕士过程中给我提供的帮助。

最后深深地感谢父母和家人默默的支持和帮助，使我能安心学业，乐观面对研究中遇到的种种困难。

本课题研究承蒙国家重点研发计划项目（2018YFB0904200）和国家自然科学基金项目（51677099）资助，特此致谢。

## 声 明

本人郑重声明：所呈交的学位论文，是本人在导师指导下，独立进行研究工作所取得的成果。尽我所知，除文中已经注明引用的内容外，本学位论文的研究成果不包含任何他人享有著作权的内容。对本论文所涉及的研究工作做出贡献的其他个人和集体，均已在文中以明确方式标明。

签 名：\_\_\_\_\_日 期：\_\_\_\_\_

## 个人简历、在学期间发表的学术论文

### 个人简历

1994 年 10 月出生于天津市。

2013 年 8 月考入清华大学电气工程与应用电子技术系电气工程与自动化专业，2017 年 7 月本科毕业并获得工学学士学位。

2017 年 9 月免试保送清华大学电机工程与应用电子技术系攻读工学硕士学位至今，师从乔颖副研究员。

### 发表的学术论文

- [1] Zhang Yujing, Qiao Ying, Lu Zongxiang. Wang Wei. New Dimensionality Reduction Method of Wind Power Curve Based on Deep Learning[C]. POWERCON, 2018:1-6 (EI 会议)
- [2] 张宇精, 乔颖, 鲁宗相, 王玮. 含高比例分布式电源接入的低感知度配电网电压控制方法[J]. 电网技术 (已录用, EI 源刊)